

# ANÁLISE DE REDES

## Conceitos Básicos

Licenciatura em  
Ciência de Dados

1

## Conceitos Básicos

- \* **Rede**
- \* Uma **rede** ou **grafo** (network ou graph)  $G$  :
  - \* é constituída por dois conjuntos -  $V$  e  $A$ ;
  - \*  $V$  é o conjunto de **nodos** (nodes), ou conjunto de **vértices** (vertices, vertex (sing.));
  - \*  $A$  é o conjunto de **ligações** (links), é constituído por pares ordenados de nodos;
  - \*  $A$  também pode ser designado por conjunto de **arcos** (arcs) ou conjunto de **arestas** (edges).

2

1


## Conceitos Básicos

- \* **Rede**
- \*  $N$  representa o número de nodos;
- \*  $L$  representa o número de ligações.

3

## Conceitos Básicos

- \* **Exemplo de uma Rede**
- \* Nesta rede representam-se um conjunto de 12 pessoas e as suas ligações no *facebook*.




4

2

## Conceitos Básicos

### \* Exemplo de uma Rede (continuação)



- \*  $V = \{A, B, C, D, E, F, J, L, M, R, S, T\}; N = 12;$
- \*  $(S,M) \in A$  (ou  $(M,S) \in A$ );  $L = 16.$

5

## Conceitos Básicos

### \* Rede

- \* Um lacete (loop) é uma ligação que une o mesmo nodo.
- \* A ligação (1,1) é um lacete.

6

## Conceitos Básicos

- \* **Redes Orientadas e Redes não Orientadas**
- \* Se as ligações não têm orientação, a rede é **não orientada** (*undirected network*).
- \* Se as ligações têm orientação, a rede é **orientada** (*directed network*).
- \* As redes orientadas também são designadas por **digrafos** (*digraphs*).

7


## Conceitos Básicos

- \* **Redes Orientadas e Redes não Orientadas**
- \* A rede do exemplo anterior é não orientada.
- \* As ligações de uma rede não orientada também são designadas por **arestas** (*edges*).
- \* As ligações de uma rede orientada também são designadas por **arcos** (*arcs*).

8

## Conceitos Básicos


- \* Exemplo de uma Rede Orientada
- \* Nesta rede representam-se as mensagens enviadas por um conjunto de 12 pessoas.



9

## Conceitos Básicos

- \* Exemplo de uma Rede Orientada (continuação)




- \*  $N = 12, L = 17$ .

10

## Conceitos Básicos

### \* Exemplo de uma Rede Orientada (continuação)



- \* A ligação (D,A) representa o envio de uma ou mais mensagens de D para A.

11

## Conceitos Básicos

### \* Exemplos de redes orientadas:

- \* a Web,
- \* a Wikipedia,
- \* o Twitter,
- \* a rede de emails,
- \* as redes biológicas,
- \* as redes de transportes.

12

## Conceitos Básicos

- \* **Redes com pesos associados às ligações**
- \* Diversas redes não têm pesos associados às ligações (*unweighted networks*).
- \* Outras redes têm atributos associados às ligações (*weighted networks*).
- \* Estes pesos podem representar a interacção entre os diferentes nodos, que pode não ser igual para todos os pares de nodos.
- \* Torna-se então relevante representar a intensidade ou o valor do fluxo entre os nodos através de pesos associados às ligações.

13

## Conceitos Básicos

- \* **Redes com pesos associados às ligações**
- \* Os pesos podem representar:
  - \* a antiguidade, em número de anos, da relação de amizade no Facebook;
  - \* o número de mensagens enviadas ou o volume de *email*,
  - \* o número de *retweets*,
  - \* o número de passageiros, numa rede de transporte.

14

## Conceitos Básicos

- \* **Nodos Adjacentes**
- \* Se  $(i,j)$  é uma ligação da rede  $G$  então nodos  $i$  e  $j$  são **nodos adjacentes** (*adjacent nodes*),  $i$  é adjacente de  $j$  e  $j$  é adjacente de  $i$ .
- \* Em inglês também se pode utilizar o termo *neighbor* para nodo adjacente.

15

## Conceitos Básicos

- \* **Densidade e Esparsidade de Redes**
- \* **Rede Completa** (*complete network*)
  - \* Uma rede é **completa** (*complete network*) se existe uma ligação entre cada nodo e cada um dos restantes.
  - \* Representa-se o número máximo de ligações por  $L_{max}$ .

16



## Conceitos Básicos

- \* **Densidade e Esparsidade de Redes**

- \* **Rede Completa** (*complete network*)

- \* Para redes não orientadas

$$L_{max} = N(N - 1)/2;$$

- \* Para redes orientadas

$$L_{max} = N(N - 1).$$

17

## Conceitos Básicos

- \* **Densidade e Esparsidade de Redes**

- \* **Densidade**

- \* A **densidade** (*density*),  $d$ , é uma medida relativa que relaciona o número de ligações existentes numa rede com o número máximo possível de ligações.

$$d = \frac{L}{L_{max}}$$

18

## Conceitos Básicos

- \* **Densidade e Esparsidade de Redes**

- \* **Densidade**

- \* Para redes não orientadas

$$d = 2L/N(N - 1);$$

- \* Para redes orientadas

$$d = L/N(N - 1).$$


19

## Conceitos Básicos

- \* **Densidade e Esparsidade de Redes**

- \* **Densidade**

- \* **Exercício 1 a)**




20

10

## Conceitos Básicos

- \* Densidade e Esparsidade de Redes
- \* Densidade
- \* Exercício 2 a)



21

## Conceitos Básicos

- \* Densidade e Esparsidade de Redes
- \* Redes Esparsas e Redes Densas
- \* Uma rede é **esparsa** (*sparse*) se o número de ligações for bastante inferior a  $L_{max}$  (se  $L \ll L_{max}$ ).
- \* Caso contrário, a rede é **densa** (*dense*).
- \* Em geral, as redes reais são esparsas.

22

## Conceitos Básicos

- \* **Densidade e Esparsidade de Redes**
- \* **Redes Esparsas e Redes Densas**
- \* As redes anteriores são esparsas, porque  $16 \ll 66$  e  $17 \ll 132$ .

23


## Conceitos Básicos

- \* **Subredes**
- \* Uma subrede (*subnetwork*) consiste numa rede que se obtém considerando apenas um subconjunto de nodos e todas as ligações da rede original que unem os elementos do subconjunto.
- \* Este conceito aplica-se tanto a redes não orientadas como a redes orientadas.

24



## Conceitos Básicos

### \* Exemplo



gerada por  $V_1 = \{A, B, D, T\}$ .


é uma subrede de



25



## Conceitos Básicos

### \* Exemplo



gerada por  $V_2 = \{B, D, E, J\}$ .

é uma subrede de



26

13

## Conceitos Básicos

- \* **Subredes**
- \* Uma clique (clique) é uma subrede completa.
- \* A subrede do exemplo anterior é uma clique.

27

## Conceitos Básicos

- \* **Subredes**
- \* Um caso particular de subredes é a rede ego (ego network) de um nodo.
- \* Esta subrede é gerada pelo subconjunto de nodos cujos elementos são o nodo escolhido e os seus adjacentes.
- \* Estas redes são frequentemente estudadas em ciências sociais.

28

## Conceitos Básicos

- \* **Grau**
- \* **Grau de um nodo de uma rede não orientada**
- \* O grau (degree) de um nodo  $i$  de uma rede não orientada é o número de ligações incidentes nesse nodo e representa-se por  $k_i$ .
- \* Na determinação do grau, um lacete é contabilizado como duas ligações.

29

## Conceitos Básicos

- \* **Grau**
- \* **Grau de um nodo de uma rede não orientada**
- \* A média dos graus dos nodos de uma rede é designada por grau médio (average degree) e representa-se por  $\langle k \rangle$ .

$$\langle k \rangle = \frac{\sum_i k_i}{N}$$

é equivalente a

$$\langle k \rangle = \frac{2L}{N}$$

30

## Conceitos Básicos

- \* **Grau**
- \* **Grau de um nodo de uma rede não orientada**
- \* **Atendendo à definição de densidade, o grau médio também pode ser expresso como:**  


$$\langle k \rangle = d(N - 1).$$
- \* **Equivalentemente**

$$d = \frac{\langle k \rangle}{N - 1}.$$

31

## Conceitos Básicos

- \* **Grau**
- \* **Grau de um nodo de uma rede não orientada**
- \* **Exercício 1 b)**



32

16



## Conceitos Básicos

- \* **Grau**
- \* **Grau de um nodo de uma rede orientada**
- \* Numa rede orientada, a orientação das ligações é relevante.
- \* Assim, definem-se o grau incidente e o grau divergente.

33

## Conceitos Básicos

- \* **Grau**
- \* **Grau de um nodo de uma rede orientada**
- \* O **grau incidente** (*in-degree*) de um nodo  $i$  de uma rede orientada é o número de ligações incidentes nesse nodo (que se dirigem ao nodo) e representa-se por  $k_i^{in}$ .
- \* O **grau divergente** (*out-degree*) de um nodo  $i$  de uma rede orientada é o número de ligações divergentes desse nodo (que partem do nodo) e representa-se por  $k_i^{out}$ .

34


## Conceitos Básicos

- \* **Grau**
- \* **Grau de um nodo de uma rede orientada**
- \* O grau médio incidente (average in-degree) [grau médio divergente (average out-degree)] pode ser calculado dividindo a soma dos graus incidentes [graus divergentes] pelo número de nodos e representa-se por  $\langle k^{in} \rangle$  [ $\langle k^{out} \rangle$ ].

35

## Conceitos Básicos

- \* **Grau**
- \* **Grau de um nodo de uma rede orientada**
- \* **Exercício 2 b)**



36

18

## Conceitos Básicos

- \* **Grau**
- \* **Grau de um nodo de uma rede não orientada com pesos associados às ligações**
- \* Seja  $G$  uma rede não orientada com pesos associados às ligações, representados por  $w_{ij}$ :  $(i, j) \in A$ .
- \* O grau ponderado ou força de um nodo (*weighted degree* ou *strength*) é dado por:

$$s_i = \sum_j w_{ij}.$$

37


## Conceitos Básicos

- \* **Grau**
- \* **Grau de um nodo de uma rede não orientada com pesos associados às ligações**
- \* O grau médio ponderado ou força média (*average weighted degree* ou *average strength*) pode ser calculado dividindo a soma dos graus ponderados pelo número de nodos e representa-se por  $\langle s \rangle$ .

38

## Conceitos Básicos

- \* **Grau**
- \* **Grau de um nodo de uma rede não orientada com pesos associados às ligações**
- \* **Exercício 3 a)**



39

## Conceitos Básicos

- \* **Grau**
- \* **Grau de um nodo de uma rede orientada com pesos associados às ligações**
- \* **Seja  $G$  uma rede orientada com pesos associados às ligações, representados por  $w_{ij}$  em que  $(i, j) \in A$ .**
- \* **O grau incidente ponderado ou força incidente de um nodo (*weighted in-degree* ou *in-strength*) é dado por:**

$$s_j^{in} = \sum_i w_{ij}.$$

40

20

## Conceitos Básicos

- \* **Grau**
- \* **Grau de um nodo de uma rede orientada com pesos associados às ligações**
- \* O grau divergente ponderado ou força divergente de um nodo (*weighted out-degree* ou *out-strength*) é dado por:

$$s_i^{out} = \sum_j w_{ij}.$$

41

## Conceitos Básicos

- \* **Grau**
- \* **Grau de um nodo de uma rede orientada com pesos associados às ligações**
- \* O grau médio incidente ponderado ou força média incidente (*average weighted in-degree* ou *average in-strength*) pode ser calculado dividindo a soma dos graus incidentes ponderados pelo número de nodos e representa-se por  $\langle s^{in} \rangle$ .

42

21


## Conceitos Básicos

- \* **Grau**
- \* **Grau de um nodo de uma rede orientada com pesos associados às ligações**
- \* O **grau médio divergente ponderado** ou **força média divergente** (*average weighted out-degree* ou *average out-strength*) pode ser calculado dividindo a soma graus divergentes ponderados pelo número de nodos e representa-se por  $\langle s^{out} \rangle$ .

43

## Conceitos Básicos

- \* **Grau**
- \* **Grau de um nodo de uma rede orientada com pesos associados às ligações**
- \* **Exercício 4 a)**



44

22

## Conceitos Básicos

- \* **Utilização dos Conceitos de Grau para caracterizar a Web**
- \* A Web pode ser representada numa rede.
- \* Os documentos são representados nos nodos e as ligações da rede representam as hiperligações.
- \* Esta rede é designada por grafo da Web (Web graph).
- \* Diversos estudos sobre os graus das páginas da Web têm sido realizados utilizando *crawlers*.

45

## Conceitos Básicos

- \* **Utilização dos Conceitos de Grau para caracterizar a Web**
- \* Estes estudos indicam que o grau médio incidente (número de hiperligações para uma página) se situa entre 10 e 30.
- \* Contudo, o desvio padrão é ainda superior.
- \* Assim, a média não é uma boa medida para caracterizar esta rede.

46

## Conceitos Básicos

- \* **Utilização dos Conceitos de Grau para caracterizar a Web**
- \* Passados poucos anos após o surgimento desta rede, verificou-se que a distribuição do grau incidente era assimétrica.
- \* Com o aumento da dimensão da Web, a ordem de grandeza de muitos nodos da rede cresceu, mas a assimetria permaneceu.

47

## Conceitos Básicos

- \* **Utilização dos Conceitos de Grau para caracterizar a Web**
- \* A análise da distribuição do grau divergente é mais difícil.
- \* É fácil encontrar páginas com muitas ligações dirigidas para outras páginas, contudo a distribuição do grau divergente não mostra a mesma ordem de grandeza que a distribuição de grau incidente.

48



## Conceitos Básicos

- \* **Utilização dos Conceitos de Grau para caracterizar a Web**
- \* Isto pode dever-se também ao facto dos *crawlers* frequentemente truncarem as páginas muito longas, não se obtendo informação fiável sobre o grau divergente.
- \* Por outro lado, uma página com demasiadas ligações orientadas para outras páginas é típica de um comportamento de *spam*.

49

## Conceitos Básicos

- \* **Utilização dos Conceitos de Grau para caracterizar a Web**
- \* Quando uma página ou documento tem ligações incidentes que provêm de páginas com grau incidente nulo, então está-se provavelmente perante *spam*.
- \* Pelo contrário, se uma página ou documento tem ligações incidentes que provêm de páginas com grau incidente elevado, então é expectável que a página ou documento tenha prestígio ou qualidade elevada.

50

25

## Conceitos Básicos

- \* **Redes Multicamada**
- \* As ligações de cada uma das redes já consideradas representam apenas um tipo de relação entre os nodos.
- \* Pode ser vantajoso representar numa mesma rede diversos tipos de relação entre os nodos.
- \* Por exemplo, para o transporte entre diversas cidades, algumas ligações podem representar o transporte aéreo, enquanto que outras representam o transporte ferroviário.

51

## Conceitos Básicos

- \* **Redes Multicamada**
- \* Neste caso, em cada camada (*layer*) da rede as ligações representam um destes tipos de transporte e obtém-se uma **rede multicamada** (*multilayer network*).
- \* Outro exemplo pode ser obtido considerando um conjunto de pessoas. Pode ser necessário representar, em simultâneo, diversos tipos de relação (amizade, laços familiares, relações laborais,...).

52

26

## Conceitos Básicos

- \* **Redes Temporais**
- \* Outras redes, ainda não mencionadas, são as **redes temporais** (*temporal networks*).
- \* Nestas redes as ligações são dinâmicas, no sentido em que as interações entre os nodos ocorrem e mudam ao longo do tempo.

53

## Conceitos Básicos

- \* **Redes Temporais**
- \* Podem considerar-se alguns intervalos de tempo. A rede associada a cada intervalo pode ser considerada uma camada (*layer*) de uma rede multicamada.
- \* A agregação de todos os intervalos de tempo permite obter uma rede estática.

54


## Conceitos Básicos

- \* Estruturas de dados utilizadas para representar redes
- \* **Matriz de Adjacência**
- \* Na matriz de adjacência (*adjacency matrix*), usualmente representada por  $A$ , o elemento  $a_{ij}$  toma o valor 1 se existe a ligação  $(i, j)$  e o valor 0, no caso contrário.

55

## Conceitos Básicos

- \* Estruturas de dados utilizadas para representar redes
- \* **Exemplo (Matriz de Adjacência)**



56


## Conceitos Básicos

- \* Estruturas de dados utilizadas para representar redes
- \* **Matriz de Adjacência**
- \* Para redes não orientadas contém informação em duplicado.
- \* Para redes esparsas contém muitos zeros.
- \* É uma estrutura bastante conhecida, mas não é eficiente.

57

## Conceitos Básicos

- \* Estruturas de dados utilizadas para representar redes
- \* **Matriz de Adjacência**
- \* **Exercício 5 a)**



58

29


## Conceitos Básicos

- \* Estruturas de dados utilizadas para representar redes
- \* Matriz de Adjacência para redes com pesos associados às ligações
- \* Os elementos iguais a 1 são substituídos pelo peso da ligação associada.

59

## Conceitos Básicos

- \* Estruturas de dados utilizadas para representar redes
- \* Matriz de Adjacência para redes com pesos associados às ligações
- \* Exercício 3 b)




60

30

## Conceitos Básicos

- \* Estruturas de dados utilizadas para representar redes
- \* Matriz de Adjacência para redes com pesos associados às ligações
- \* Exercício 4 b)



61

## Conceitos Básicos

- \* Estruturas de dados utilizadas para representar redes
- \* Lista de Ligações
- \* A lista de ligações (*edge list* ou *arc list*) consiste em dois vectores.
- \* Num dos vectores indica-se um dos extremos de cada ligação. No outro vector, na componente homóloga, indica-se o outro extremo da ligação.

62


## Conceitos Básicos

- \* Estruturas de dados utilizadas para representar redes
- \* Lista de Ligações
- \* A lista de ligações também pode ser representada numa matriz com duas colunas.

63

## Conceitos Básicos

- \* Estruturas de dados utilizadas para representar redes
- \* Exemplo (Lista de Ligações)



A	A	A	B	D
---	---	---	---	---

B	D	T	D	T
---	---	---	---	---

A ligação (A,B) está representada apenas uma vez.

64

32




## Conceitos Básicos

- \* Estruturas de dados utilizadas para representar redes
- \* Lista de Adjacência
- \* A lista de adjacência (*adjacency list*) consiste em dois vectores.

65

## Conceitos Básicos

- \* Estruturas de dados utilizadas para representar redes
- \* Lista de Adjacência
- \* Exemplo



66

## Conceitos Básicos

- \* Estruturas de dados utilizadas para representar redes

- \* Lista de Adjacência 

1	4	6	9	11
---	---	---	---	----

- \* Exemplo

B	D	T	A	D	A	B	T	A	D
---	---	---	---	---	---	---	---	---	---

- \* No segundo vector, nas componentes de 1 a (4-1) estão os nodos adjacentes de A, de 4 a (6-1) estão os adjacentes de B,...

67

## Conceitos Básicos

- \* Estruturas de dados utilizadas para representar redes

- \* Lista de Adjacência 

1	4	6	9	11
---	---	---	---	----

- \* Exemplo

B	D	T	A	D	A	B	T	A	D
---	---	---	---	---	---	---	---	---	---

- \* Nesta lista, a ligação (A,B) está representada duas vezes. B é nodo adjacente de A (primeira componente do segundo vetor) e A é nodo adjacente de B (quarta componente do segundo vetor)

68

## Conceitos Básicos

- \* Estruturas de dados utilizadas para representar redes
- \* Listas para redes com pesos associados às ligações
- \* Acrescenta-se um terceiro vector com os pesos das ligações.

69

## Conceitos Básicos

- \* **Representação Gráfica de Redes**
- \* Pode ser útil para identificar e visualizar algumas propriedades e características das redes.
- \* Por exemplo, quais são os nodos com grau bastante mais elevado do que os restantes.

70


## Conceitos Básicos

- \* Casos Particulares de Redes
- \* Rede em Estrela (*star network*)
  - \* Um e um só nodo está ligado a todos os restantes;
  - \* Não existem outras ligações, além das anteriores.

71

## Conceitos Básicos

- \* Casos Particulares de Redes
- \* Rede em Estrela (*star network*)
- \* Exemplo



72

## Conceitos Básicos

- \* **Casos Particulares de Redes**
- \* **Redes Bipartidas** (*bipartite networks*)
  - \* o conjunto dos nodos está dividido em dois subconjuntos, um com  $N_1$  nodos e o outro com  $N_2$  nodos;
  - \* os nodos adjacentes pertencem a conjuntos diferentes, o que significa que não existem ligações entre os nodos de um mesmo subconjunto.

73

## Conceitos Básicos

- \* **Casos Particulares de Redes**
- \* **Redes Bipartidas** (*bipartite networks*)
- \* **Exemplo**
  - \* Um dos subconjuntos de nodos representa as doenças humanas;
  - \* O outro subconjuntos é constituído pelos genes cujas mutações originam e influenciam as doenças;
  - \* As ligações unem doenças e genes.

74


## Conceitos Básicos

- \* Casos Particulares de Redes
- \* Redes Bipartidas (*bipartite networks*)
- \* Exemplo
  - \* Um dos subconjuntos de nodos representa atores;
  - \* O outro subconjuntos é constituído por filmes;
  - \* Cada ligação une um ator a um filme se o ator representou um papel nesse filme.

75

## Conceitos Básicos

- \* Casos Particulares de Redes
- \* Redes Bipartidas (*bipartite networks*)
- \* Exemplo



76

## Conceitos Básicos

- \* **Casos Particulares de Redes**
- \* **Redes Bipartidas** (*bipartite networks*)
- \* A partir de uma rede bipartida, podem obter-se outras duas redes em que o conjunto dos nodos é apenas um dos subconjuntos da rede bipartida.
- \* Cada uma destas novas redes é designada por **projeção** (*projection*).

77


## Conceitos Básicos

- \* **Casos Particulares de Redes**
- \* **Redes Bipartidas** (*bipartite networks*)
- \* As ligações de uma projeção são os pares ordenados de nodos que partilham pelo menos um nodo adjacente na rede bipartida.

78

## Conceitos Básicos

- \* Casos Particulares de Redes
- \* Redes Bipartidas (bipartite networks)
- \* Exemplo



79

## Conceitos Básicos

- \* Casos Particulares de Redes
- \* Redes Bipartidas (bipartite networks)
- \* Por exemplo, se numa rede bipartida se tem um conjunto de doenças humanas e um conjunto de genes, as ligações unem as doenças e os genes que as originam.
- \* Então uma projeção é obtida para as doenças. Nesta rede, uma ligação entre doenças indica que ambas estão associadas a mutações em, pelo menos, um gene comum.

80



## Conceitos Básicos

- \* **Casos Particulares de Redes**
- \* **Redes Bipartidas** (*bipartite networks*)
- \* A outra projeção refere-se aos genes. Uma ligação entre dois genes indica que uma ou mais doenças são provocadas por mutações nos dois genes.

81

## Conceitos Básicos

- \* **Casos Particulares de Redes**
- \* **Redes Bipartidas** (*bipartite networks*)
- \* **Redes Co-ocorrentes**
- \* Se a projeção resultante for uma rede com pesos associados às ligações então é designada por **rede co-ocorrente** ou **rede de co-ocorrência** (*co-occurent network*).
- \* Na projeção da rede bipartida das doenças humanas, pode ter-se o número de genes em comum causadores do par de doenças ou o número de doenças causadas por mutações nos dois genes.

82

41

## Conceitos Básicos

- \* **Casos Particulares de Redes**
- \* **Redes Bipartidas** (*bipartite networks*)
- \* As redes bipartidas também podem representar consumo de bens ou serviços. Neste caso, as projecções podem ser úteis para identificar padrões de consumo.
- \* **Exercício 8**

83

## Conceitos Básicos

- \* **Casos Particulares de Redes**
- \* **Redes Bipartidas** (*bipartite networks*)
- \* Se  $N_1$  e  $N_2$  representam, respectivamente, o número de nodos do primeiro e do segundo subconjuntos então
 
$$L_{max} = N_1 \times N_2.$$
- \* A densidade de uma rede bipartida é dada por
 
$$d = L / (N_1 \times N_2).$$

84

## Conceitos Básicos

- \* **Casos Particulares de Redes**
- \* **Redes Bipartidas** (*bipartite networks*)
- \* As redes tripartidas são uma generalização das redes bipartidas.
- \* Nestas redes o conjunto de nodos é constituído por três subconjuntos de nodos, por exemplo,  $V_1$ ,  $V_2$  e  $V_3$ .
- \* Existem dois subconjuntos de ligações - ligações entre  $V_1$  e  $V_2$ ; e entre  $V_2$  e  $V_3$ .

85

## Conceitos Básicos

- \* **Casos Particulares de Redes**
- \* **Redes Bipartidas** (*bipartite networks*)
- \* Estas redes tripartidas podem ser utilizadas para representar os nutrientes presentes em receitas de culinária.
- \* Um dos subconjuntos representa as receitas, outro representa os ingredientes e o terceiro subconjunto refere-se aos nutrientes.

86

## Conceitos Básicos

- \* **Casos Particulares de Redes**
- \* **Redes Bipartidas** (*bipartite networks*)
- \* Em alguns contextos, pode obter-se uma rede bipartida, a partir de uma rede tripartida.
- \* Também se podem obter projeções de redes tripartidas num só conjunto de nodos.

87

## Conceitos Básicos

- \* **Casos Particulares de Redes**
- \* **Redes Bipartidas** (*bipartite networks*)
- \* Por exemplo, a partir da rede em que representam as receitas, os ingredientes e os nutrientes pode obter-se uma rede em que se representam apenas os ingredientes.
- \* Entre os ingredientes que partilham, pelo menos, um nutriente existe uma ligação.

88

## Conceitos Básicos

- \* **Casos Particulares de Redes**
- \* **Redes Bipartidas** (*bipartite networks*)
- \* Os nodos podem ser representados com dimensões diferentes. A dimensão representará a prevalência do ingrediente nas receitas.
- \* A espessura das ligações pode ser proporcional ao número de nutrientes partilhados.

# ANÁLISE DE REDES

## *Small Worlds*

Licenciatura em  
Ciência de Dados

## *Small Worlds*

- \* Vamos estudar três características das redes:
  - \* semelhança entre nodos adjacentes;
  - \* existência de caminhos curtos entre os nodos;
  - \* existência de triângulos formados por nodos adjacentes.

## Small Worlds

- \* As redes sociais são algumas das redes em que as características mencionadas estão presentes.
- \* Numa rede social:
  - \* as pessoas são representadas nos nodos,
  - \* as ligações representam as relações (amizade, laços familiares, conhecimento, trabalho) entre as pessoas.

3

## Small Worlds


- \* **Associação (Assortativity)**
- \* Em muitas redes existem ligações entre nodos que representam entidades com algumas características comuns.
- \* Esta associação é designada em inglês por *assortativity*.

4

## Small Worlds

### \* Exemplo 1

\* Considere-se a rede com 7 nodos e 11 ligações:



5

## Small Worlds

### \* Exemplo 1

- \* Verifica-se que existe uma ligação entre cada par de nodos do subconjunto  $\{1, 2, 3, 4\}$ .
- \* Apenas 2 e 4 estão ligados a nodos que não pertencem ao subconjunto.
- \* Para o subconjunto  $\{5, 6, 7\}$  ocorre algo semelhante.


6



## Small Worlds

### \* Exemplo 1

- \* Pode concluir-se que a maioria das ligações desta rede unem elementos do mesmo subconjunto.



7

## Small Worlds

- \* As redes sociais são exemplos de redes em que as ligações representam relações que traduzem alguma semelhança entre os nodos.
- \* Em geral, os amigos partilham características, opiniões comuns e tendem a tornar-se mais parecidos ao longo do tempo.
- \* Este fenómeno pode dever-se ao facto de as semelhanças aproximarem as pessoas ou as semelhanças ocorrerem por influência das pessoas com quem convivem.

## Small Worlds

- \* Por outro lado, em algumas destas redes, verifica-se uma divisão dos nodos em subconjuntos, havendo uma polarização.
- \* Este fenómeno **pode ter consequências negativas** (manipulação de opinião, desinformação, ...), que têm sido estudadas.

9

## Small Worlds

- \* Associação de grau (*degree assortativity*)
- \* A associação (*assortativity*) não é exclusiva das redes sociais.
- \* Em algumas redes, a associação está presente no grau dos nodos.
- \* Este tipo de associação é designado por associação de grau (*degree assortativity*) ou correlação de grau (*degree correlation*).

10

## Small Worlds

- \* Associação de grau (*degree assortativity*)
- \* Ocorre quando os nodos de maior grau estão ligados principalmente a nodos de grau elevado e os de menor grau estão unidos principalmente a nodos de grau reduzido.

11

## Small Worlds

- \* Rede associativa (*assortative network*)
- \* Uma rede com a propriedade anterior é designada por rede associativa (*assortative network*).
- \* Nestas redes, a parte mais densa é constituída pelos nodos de maior grau, enquanto que os de menor grau constituem a estrutura periférica.

12

## Small Worlds

- \* Rede associativa (*assortative network*)
- \* No caso dos nodos de maior grau estarem ligados aos de menor grau, a rede é não associativa (*disassortative*).
- \* Uma rede que não é associativa nem não associativa é uma rede neutra (*neutral network*).

13

## Small Worlds

- \* Rede associativa (*assortative network*)
- \* A Web, a rede de emails e as redes biológicas são redes não associativas.
- \* A rede de electricidade é neutra.

14

## Small Worlds

- \* **Rede associativa** (*assortative network*)
- \* A associação baseada no grau pode ser medida de duas formas:
  - \* a primeira consiste em determinar o coeficiente de correlação de Pearson para os graus de nodos adjacentes;
  - \* a segunda forma é baseada no grau médio dos nodos adjacentes de cada nodo.

15

## Small Worlds

- \* **Rede associativa** (*assortative network*)
- \* O coeficiente de correlação de Pearson toma valores entre -1 e 1.
- \* Se o valor for nulo, significa que não existe correlação.
- \* Se tomar o valor 1, a correlação é positiva perfeita. Para o valor -1, a correlação é negativa perfeita.

16

## Small Worlds

- \* **Rede associativa** (*assortative network*)
- \* Uma correlação entre duas variáveis é positiva se valores elevados de uma das variáveis estão associados a valores elevados da outra variável.
- \* É negativa se valores elevados de uma das variáveis estão associados a valores reduzidos da outra variável.

17

## Small Worlds

- \* **Rede associativa** (*assortative network*)
- \* Se o coeficiente toma um valor significativo positivo então a rede é associativa.
- \* Se o valor do coeficiente for significativo e negativo então a rede é não associativa.
- \* **Ser não associativa  $\neq$  não ser associativa**

18


## Small Worlds

- \* Rede associativa (*assortative network*)
- \* O valor do coeficiente pode não ser significativo ou difícil de interpretar, sendo necessária outra abordagem.
- \* **Ser não associativa  $\neq$  não ser associativa**

19

## Small Worlds

- \* Rede associativa (*assortative network*)
- \* **Exemplo 1 (continuação)**




- \* O valor do coeficiente de correlação de Pearson é igual a 0,043.
- \* Conclusão?

20

## Small Worlds

\* Rede associativa (*assortative network*)

\* Exemplo 1 (continuação)




\* Trata-se de um valor positivo mas pouco significativo, o que não permite considerar que a rede é associativa.

21

## Small Worlds

\* Rede associativa (*assortative network*)

\* Exemplo 1 (continuação)



\* Este resultado não surpreende, pois dois dos sete nodos estão ligados não só aos nodos com maior grau, mas também ao nodo com menor grau. A rede é neutra.

22



## Small Worlds

\* **Rede associativa** (*assortative network*)

\* **Exemplo 1** (continuação)

Nodo i	Nodo j	Grau de i	Grau de j
1	2	3	4
1	3	3	3
1	4	3	4
2	1	4	3
...	...	...	...

\* Correlação entre o grau de i e o grau de j.

23

## Small Worlds

\* **Rede associativa** (*assortative network*)

\* Para medir a associação de grau com base no grau médio dos nodos adjacentes considere-se

$$k_{nn}(i) = \frac{1}{k_i} \sum_j a_{ij} k_j$$

em que  $a_{ij} = 1$  se  $i$  e  $j$  são adjacentes e 0, no caso contrário.

24


## Small Worlds

- \* **Rede associativa** (*assortative network*)
- \* Seja também a função  $\langle k_{nn}(k) \rangle$  que consiste na média dos valores  $k_{nn}(i)$  calculada para os nodos  $i$  com grau igual a  $k$ .
- \* Se esta função é crescente então a rede é associativa.
- \* Se a função é decrescente então a rede é não associativa.

25

## Small Worlds

- \* **Rede associativa** (*assortative network*)
- \* **Exemplo 1 (continuação)**



$$k_{nn}(1) = \frac{1}{3}(4 + 3 + 4) = \frac{11}{3}; \quad k_{nn}(2) = \frac{1}{4}(3 + 3 + 4 + 3) = \frac{13}{4}$$

26

## Small Worlds

- \* Rede associativa (*assortative network*)
- \* Exemplo 1 (continuação)


Nodos	$k_{nn}$	Nodos	$k_{nn}$	Grau	$\langle k_{nn} \rangle$
1	11/3	5	3	2	3
2	13/4	6	3	3	10/3
3	11/3	7	3	4	13/4
4	13/4				

- \* Conclusão?

27

## Small Worlds

- \* Rede associativa (*assortative network*)
- \* Exercício 1 a) - c)



28

## Small Worlds


### \* Caminhos e Distâncias

- \* Numa rede existem  $L$  ligações.
- \* Estas ligações permitem unir diversos pares de nodos através de uma sequência de ligações.
- \* Um caminho (*path*) é uma sequência de ligações que une um par de nodos. Cada par de ligações consecutivas tem, pelo menos, um extremo em comum.
- \* No caso das redes orientadas, esta sequência tem que ter em conta a orientação das ligações.

29

## Small Worlds

### \* Caminhos e Distâncias




$\{(1,2), (2,3), (3,4), (4,5)\}$  e  $\{(1,2), (2,4), (4,5)\}$  são dois caminhos entre 1 e 5.

Não existem caminhos entre 1 e 6.

30

## Small Worlds

### \* Caminhos e Distâncias



$\{(1,2), (2,3), (3,4), (4,5)\}$  e  $\{(1,2), (2,4), (4,5)\}$  são dois caminhos entre 1 e 5.

Não existem caminhos entre 5 e 1.

31

## Small Worlds


### \* Caminhos e Distâncias

- \* Para redes sem pesos associados às ligações, o **comprimento de um caminho** (*path length*) é o número de ligações consideradas no caminho.
- \* Para redes com pesos associados às ligações, o **comprimento de um caminho** é a soma dos pesos das ligações que constituem o caminho.

32

## Small Worlds

### \* Caminhos e Distâncias




$\{(1,2), (2,3), (3,4), (4,5)\}$  tem comprimento igual a 4.

$\{(1,2), (2,4), (4,5)\}$  tem comprimento igual a 3.

33

## Small Worlds

### \* Caminhos e Distâncias



$\{(1,2), (2,3), (3,4), (4,5)\}$  tem comprimento igual a 7.

$\{(1,2), (2,4), (4,5)\}$  tem comprimento igual a 9.

34

## Small Worlds


### \* Caminhos e Distâncias

- \* O caminho mais curto (*shortest path*) entre um par de nodos é o caminho entre esse par de nodos com menor comprimento.
- \* Pode existir mais do que um caminho mais curto entre um par de nodos.
- \* Um caminho simples (*simple path*) é um caminho em que não se repetem ligações.
- \* Um ciclo (*cycle*) é um caminho que parte de um nodo e regressa a esse nodo.

35

## Small Worlds

### \* Caminhos e Distâncias




$\{(1,2), (2,3), (3,4), (4,5)\}$  e  $\{(1,2), (2,4), (4,5)\}$  são caminhos simples entre 1 e 5.

$\{(1,2), (2,4), (4,5)\}$  é o caminho mais curto entre 1 e 5.

36

## Small Worlds

### \* Caminhos e Distâncias




A sequência  $\{(2,3), (3,4), (4,2)\}$  constitui um ciclo.

Existem também caminhos entre 5 e 1.

37

## Small Worlds

### \* Caminhos e Distâncias



$\{(1,2), (2,3), (3,4), (4,5)\}$  e  $\{(1,2), (2,4), (4,5)\}$  são dois caminhos entre 1 e 5.


$\{(1,2), (2,3), (3,4), (4,5)\}$  tem comprimento igual a 4.

$\{(1,2), (2,4), (4,5)\}$  tem comprimento igual a 3.



## Small Worlds

### \* Caminhos e Distâncias




$\{(1,2), (2,3), (3,4), (4,5)\}$  e  
 $\{(1,2), (2,4), (4,5)\}$  são  
 caminhos simples entre 1 e 5.

$\{(1,2), (2,4), (4,5)\}$  é o  
 caminho mais curto entre 1 e  
 5.

39

## Small Worlds

### \* Caminhos e Distâncias




A sequência  $\{(2,3), (3,4), (4,2)\}$  constitui um ciclo.

40

## Small Worlds

### \* Caminhos e Distâncias




$\{(1,2), (2,3), (3,4), (4,5)\}$  é um caminho com comprimento igual a 7.

$\{(1,2), (2,4), (4,5)\}$  é um caminho com comprimento igual a 9.

$\{(1,2), (2,3), (3,4), (4,5)\}$  é o caminho mais curto entre 1 e 5.<sup>41</sup>

## Small Worlds

### \* Caminhos e Distâncias



$\{(1,2), (2,3), (3,4), (4,5)\}$  é um caminho com comprimento igual a 6.

$\{(1,2), (2,4), (4,5)\}$  é um caminho com comprimento igual a 8.

$\{(1,2), (2,3), (3,4), (4,5)\}$  é o caminho mais curto entre 1 e 5.<sup>42</sup>

## Small Worlds

### \* Caminhos e Distâncias

- \* Vamos agora considerar o problema de determinação do número de caminhos, existentes numa rede, entre dois nodos  $i$  e  $j$  com  $k$  ligações.
- \* Este problema pode ser resolvido recorrendo à multiplicação de matrizes de adjacência.

43

## Small Worlds

### \* Caminhos e Distâncias


- \* Seja  $A$  a matriz de adjacência de uma rede sem pesos associados às ligações.
- \* Seja  $A^k$  a matriz que se obtém multiplicando  $k$  vezes a matriz  $A$ . O elemento da linha  $i$  e coluna  $j$  da matriz  $A^k$  indica o número de caminhos entre  $i$  e  $j$  com  $k$  ligações.

44

## Small Worlds

- \* Caminhos e Distâncias

- \* Exercício 1 d)



45

## Small Worlds

- \* Caminhos e Distâncias

- \* Os comprimentos dos caminhos entre os nodos podem ser utilizados para caracterizar a rede.
- \* Estes comprimentos podem medir a distância entre os nodos.
- \* Podem utilizar-se medidas de distância agregada, como a **média dos comprimentos dos caminhos mais curtos** e o **diâmetro da rede**.

46

## Small Worlds

- \* Caminhos e Distâncias

- \* Para uma rede não orientada, a média dos comprimentos dos caminhos mais curtos (*average path length* ou *average path length*) é definida como:

$$\langle l \rangle = \frac{2 \sum_{i,j} l_{ij}}{N(N-1)}$$

em que  $l_{ij}$  é o comprimento do caminho mais curto entre  $i$  e  $j$ , e  $N$  representa o número de nodos da rede.

47

## Small Worlds

- \* Caminhos e Distâncias

- \* No somatório, que figura no numerador do quociente anterior, para cada par de nodos  $(i,j)$ , considera-se  $l_{ij}$  ou  $l_{ji}$  (apenas um destes valores).

48

## Small Worlds

- \* Caminhos e Distâncias

- \* Para uma rede orientada, a média dos comprimentos dos caminhos mais curtos é definida como:

$$\langle l \rangle = \frac{\sum_{i,j} l_{ij}}{N(N-1)}$$


- \* Neste caso, no somatório, que figura no numerador, consideram-se ambos os valores  $l_{ij}$  e  $l_{ji}$ .

49

## Small Worlds

- \* Caminhos e Distâncias

- \* Exercício 1 e)



50

## Small Worlds

- \* **Caminhos e Distâncias**

- \* No caso de não existir um caminho entre dois nodos  $i$  e  $j$ , numa rede não orientada, pode considerar-se  $l_{ij} = \infty$ .  $(1/l_{ij}) = 0$ , e

$$\langle l \rangle = \left( \frac{2(\sum_{i,j} 1/l_{ij})}{N(N-1)} \right)^{-1}.$$

- \* Para calcular esta média, começa-se por determinar a média dos inversos dos comprimentos. A média dos comprimentos será o inverso da média anterior.

51

## Small Worlds

- \* **Caminhos e Distâncias**

- \* Para as redes orientadas, a adaptação é semelhante.

52

## Small Worlds


- \* Caminhos e Distâncias
- \* Outras alternativas, para medir a distância, para redes em que não existem caminhos entre todos os pares de nodos serão sugeridas posteriormente.
- \* O diâmetro (*diameter*) de uma rede é definido como:

$$l_{max} = \max_{i,j} l_{ij}.$$

53

## Small Worlds

- \* Caminhos e Distâncias
- \* Exercício 1 f)



54



## Small Worlds

- \* **Conectividade e Componentes**

- \* O número máximo de ligações de uma rede depende do número de nodos.
- \* Muitas redes são esparsas, têm muito menos ligações do que o número máximo possível.
- \* Se o número de ligações for muito reduzido, poderão não existir caminhos entre alguns pares de nodos, não se verificando a conectividade.

55

## Small Worlds

- \* **Conectividade e Componentes**

- \* Uma rede não orientada diz-se **conexa** (*connected*) se existe, pelo menos, um caminho entre qualquer par de nodos.
- \* Caso contrário, a rede diz-se **desconexa** (*disconnected*).
- \* Uma rede não orientada desconexa é composta por **componentes conexas**.

56

## Small Worlds


### \* Conectividade e Componentes

- \* Uma componente conexa ou componente (*connected component* ou *component*) é uma subrede conexa.
- \* Se a maior das componentes conexas de uma rede envolve uma parte substancial da rede então é designada por componente gigante (*giant component*).

57

## Small Worlds

### \* Conectividade e Componentes



A rede é desconexa.

É composta por três componentes conexas:

- a subrede gerada por {1, 2, 3, 4, 5};
- a subrede gerada por {6, 7};
- a subrede gerada por {8}.

58

## Small Worlds

### \* **Conectividade e Componentes**

- \* Uma rede orientada é **fortemente conexa** (*strongly connected*) se existe, pelo menos, um caminho entre qualquer par de nodos  $(i, j)$ , de  $i$  para  $j$  e de  $j$  para  $i$ .
- \* Uma rede orientada é **fracamente conexa** (*weakly connected*) se, quando se ignora a orientação das ligações, existe, pelo menos, um caminho entre qualquer par de nodos  $(i, j)$ .

59

## Small Worlds

### \* **Conectividade e Componentes**

- \* Uma subrede de uma rede orientada é uma **componente fortemente conexa** (*strongly connected component*) se existe, pelo menos, um caminho entre qualquer par de nodos da subrede, em ambos os sentidos.

60

## Small Worlds


### \* Conectividade e Componentes

- \* Uma subrede de uma rede orientada é uma **componente fracamente conexa** (*weakly connected component*) se, quando se ignora a orientação das ligações, existe, pelo menos, um caminho entre qualquer par de nodos da subrede.

61

## Small Worlds

### \* Conectividade e Componentes




A rede não é fortemente conexa nem fracamente conexa, porque não existem caminhos para alguns pares de nodos (por exemplo, entre 1 e 6).

62

## Small Worlds

### \* Conectividade e Componentes




As subredes geradas por  $\{1, 2, 3, 4, 5\}$  e por  $\{6, 7\}$  são componentes fracamente conexas.

63

## Small Worlds

### \* Conectividade e Componentes



A subrede gerada por  $\{2, 3, 4, 5\}$  é uma componente fortemente conexa (que designaremos por  $S$ ), existe, pelo menos, um caminho entre qualquer par de nós deste subconjunto, qualquer que seja a orientação considerada.

64

## Small Worlds

### \* Conectividade e Componentes

#### \* Sejam:

- \*  $V_1$  um subconjunto de nodos de uma rede orientada;
- \*  $S$  uma componente fortemente conexa desta rede.

#### \* Se:

- \* existe um caminho entre cada elemento de  $V_1$  e os elementos de  $S$ ;
- \* não existe nenhum caminho entre os elementos de  $S$  e cada um dos elementos de  $V_1$

Então

- \*  $V_1$  é o conjunto incidente (*in-component*) em  $S$ .

65

## Small Worlds

### \* Conectividade e Componentes

#### \* Se $V_1$ é o conjunto incidente (*in-component*) em $S$


então os elementos de  $S$  podem ser alcançados a partir de  $V_1$ , mas não podem alcançar os elementos de  $V_1$

- \* Analogamente, o conjunto de nodos que podem ser alcançados (usando caminhos) a partir de  $S$ , mas não podem alcançar os elementos de  $S$  é designado por conjunto divergente (*out-component*) de  $S$ .

66

## Small Worlds

### \* Conectividade e Componentes



O conjunto  $\{1\}$  é o conjunto incidente em  $S$  (componente fortemente conexa  $\{2, 3, 4, 5\}$ ), existe um caminho entre 1 e qualquer elemento de  $S$  e não existem caminhos entre os nós de  $S$  e 1.

67

## Small Worlds

- \* **Alternativas para medir a distância numa rede em redes desconexas**
- \* Em redes desconexas, a média dos comprimentos dos caminhos mais curtos pode ser calculada considerando apenas os nós da componente gigante.
- \* Outra alternativa consiste em calcular a média das distâncias tomando apenas os pares de nós para os quais existem caminhos.

68


## Small Worlds

- \* **Alternativas para medir a distância numa rede em redes desconexas**
- \* Para o diâmetro, pode determinar-se o diâmetro de cada componente conexa e atribuir ao diâmetro da rede o máximo dos diâmetros.

69

## Small Worlds

- \* **Conectividade e Componentes**
- \* **Exercício 2**




70



## Small Worlds

### \* Conectividade e Componentes

#### \* Exercício 3



71

## Small Worlds

### \* Web, Caminhos e Componentes

- \* A maior das componentes do grafo da Web inclui mais de 90% das páginas, sendo por isso uma componente gigante.
- \* Além desta componente, existem muitas componentes de pequena dimensão.
- \* Também se observam muitas componentes fracamente conexas cuja dimensão apresenta uma distribuição enviesada (ou assimétrica).

72

## Small Worlds

- \* **Web, Caminhos e Componentes**
- \* Na componente gigante é possível identificar uma componente gigante fortemente conexa, designada usualmente por *core*.
- \* Existem também um conjunto incidente neste *core* (*in-component*) e um conjunto divergente deste *core* (*out-component*).

73

## Small Worlds

- \* **Web, Caminhos e Componentes**
- \* Frequentemente nodos que representam entidades com semelhanças ou características comuns estão unidos por ligações.
- \* Esta propriedade é designada por homofilia.
- \* Os nodos de redes de informação como as páginas da *Web*, os artigos da *Wikipedia* e artigos de publicações científicas contêm informação sobre um determinado tema ou assunto.

74

## Small Worlds

### \* **Web, Caminhos e Componentes**

- \* Com base no conteúdo é possível determinar o tema ou tópico abordado.
- \* Por outro lado, páginas ou artigos sobre tópicos relacionados podem estar ligadas entre si ou ter um caminho com poucas ligações entre elas.
- \* Quando isto acontece diz-se que a rede tem *topical locality*.

75

## Small Worlds

### \* **Web, Caminhos e Componentes**

- \* Esta propriedade surge quando os autores de novas páginas, artigos ou publicações os unem a outros com informação relevante sobre a temática ou tópico abordado.
- \* Para quantificar a *topical locality*, pode medir-se a semelhança, baseada no tema ou tópico abordado, entre uma determinada página (ou um determinado artigo), que designaremos por origem (*source*), e as páginas (ou artigos) a uma dada distância.

76

## Small Worlds

### \* **Web, Caminhos e Componentes**

- \* É expectável que a fração de páginas ou artigos, a uma distância não superior a duas ligações da origem, que partilham o mesmo tema ou tópico da origem seja superior a páginas escolhidas ao acaso.
- \* Páginas ou documentos mais afastados da origem terão menor possibilidade de partilhar o tema ou tópico. Este fenómeno é designado por *topic drift*.

77

## Small Worlds

### \* **Web, Caminhos e Componentes**

- \* Além da partilha de temas ou tópicos em páginas ou documentos próximos, também se verifica outra propriedade.
- \* A qualidade das páginas ou documentos próximas de uma origem ou semente (*seed*) de boa qualidade não será significativamente inferior à da origem ou semente.
- \* Esta é a razão pela qual os *crawlers* (programas que recolhem informação) utilizam métodos de pesquisa em largura (*breath-first search*).

78

## Small Worlds

- \* **Árvores**

- \* Uma árvore (*tree*) é uma rede não orientada, conexa e sem ciclos.
- \* Uma árvore também pode ser definida como uma rede não orientada conexa, com  $N$  nodos e  $N - 1$  ligações.
- \* Se se acrescentar alguma ligação à árvore, a rede passará a ter um ciclo.
- \* Se se remover alguma ligação da árvore, a rede deixará de ser conexa.

79

## Small Worlds


- \* **Árvores**

- \* Apesar de uma árvore ser uma rede não orientada, pode induzir-se uma hierarquia nesta rede.
- \* Esta hierarquização será feita escolhendo um dos nodos para raiz (*root*) da árvore.


80

## Small Worlds

### \* Árvores



81



## Small Worlds

### \* Árvores

- \* No exemplo anterior a mesma rede está representada graficamente de duas formas. Esta rede é uma árvore (é uma rede conexa e sem ciclos).
- \* Na representação à esquerda o nodo 2 é a raiz da árvore. Este nodo é pai (parent) dos nodos 1 e 3.
- \* Na representação à direita o nodo 6 é a raiz da árvore. Este nodo é pai (parent) do nodo 5.

82


## Small Worlds

- \* **Árvores**
- \* Alguns algoritmos utilizam a estrutura hierárquica obtida numa árvore.
- \* Se uma rede orientada não tem ciclos e existe um caminho entre a raiz e cada um dos restantes nodos, então essa rede é uma arborescência (arborescence ou directed tree).

83

## Small Worlds

- \* **Árvores**
- \* **Exercício 4**



84

## Small Worlds

- \* **Determinação dos Caminhos mais Curtos**
- \* Existem diversos algoritmos e software para determinar os caminhos mais curtos numa rede.
- \* A rede pode ter pesos associados às ligações ou não.

85

## Small Worlds

- \* **Determinação dos Caminhos mais Curtos**
- \* Considere-se uma rede sem pesos associados às ligações.
- \* O algoritmo que vamos estudar permite determinar os caminhos mais curtos entre um nodo, que designaremos por origem (source), e todos os restantes da rede.
- \* Este algoritmo considera uma representação hierárquica da rede, com diversos níveis ou camadas (layers).

86



## Small Worlds

### \* **Determinação dos Caminhos mais Curtos**

- \* No nível 0, encontra-se apenas a origem.
- \* No nível 1, colocam-se os nodos adjacentes da origem.
- \* Cada novo nível é preenchido com os nodos adjacentes dos elementos do nível anterior, caso ainda não tenham sido representados.
- \* Nesta representação, as ligações entre os nodos são as ligações da rede original.

87

## Small Worlds

### \* **Determinação dos Caminhos mais Curtos**

- \* A pesquisa começa na origem, no nível 0.
- \* Percorrem-se as ligações entre o nível 0 e o nível 1.
- \* A distância entre a origem e cada um dos nodos do nível 1 é igual a 1.

88

## Small Worlds

### \* **Determinação dos Caminhos mais Curtos**

- \* De seguida, escolhe-se um nodo do nível 1 e percorrem-se as ligações entre este nodo e os seus adjacentes do nível 2.
- \* A distância entre a origem e cada um destes últimos nodos é igual a 2.
- \* Caso existam, no nível 1, nodos ainda não considerados para pesquisa, escolhe-se um destes nodos.

89

## Small Worlds

### \* **Determinação dos Caminhos mais Curtos**

- \* Todos os nodos do nível 1 terão que ser escolhidos para efectuar pesquisa.
- \* Passa-se depois ao nível seguinte e procede-se de forma semelhante.
- \* Repete-se a pesquisa até se analisarem todos os níveis da componente ou da rede.

90

## Small Worlds

### \* Determinação dos Caminhos mais Curtos

- \* Só se efectua a pesquisa a partir de um determinado nível após a inspecção completa do nível anterior.
- \* Este tipo de pesquisa é designado, em Inglês, por *breadth-first search*.
- \* Começaremos por representar todas as ligações a tracejado. À medida que as ligações são percorridas passam a ser representadas a cheio.

91

## Small Worlds

### \* Determinação dos Caminhos mais Curtos

#### \* Descrição do algoritmo *breadth-first search*

- \* Nesta descrição utiliza-se um conjunto  $S$  de nodos. Considerem-se os seguintes passos:
  - \* 1 - Constrói-se a árvore de acordo com a descrição anterior e com as ligações a tracejado.
  - \* 2 - Seja  $s$  o nodo origem. Introduz-se  $s$  em  $S$ ,  $l(s, s) = 0$ .

92

## Small Worlds

- \* **Determinação dos Caminhos mais Curtos**
- \* **Descrição do algoritmo *breadth-first search***
  - \* 3 - Se  $S = \emptyset$  então o algoritmo termina.  
Caso contrário, retira-se de  $S$  um dos nodos com menor índice de nível na árvore. Seja  $i$  esse nodo e  $k$  o seu nível na árvore.

93

## Small Worlds


- \* **Determinação dos Caminhos mais Curtos**
- \* **Descrição do algoritmo *breadth-first search***
  - \* 4 - Incluem-se em  $S$  os nodos adjacentes de  $i$  que estão no nível  $k + 1$ . Para cada um destes nodos, que se representam por  $j$ ,  $l(s, j) = l(s, i) + 1$  e desenham-se as ligações  $(i, j)$  a cheio.
  - \* 5 - Volta-se ao Passo 3.

94

## Small Worlds

- \* **Determinação dos Caminhos mais Curtos**

- \* **Exemplo**



- \* **Quais são os caminhos mais curtos entre 1 e cada um dos restantes nodos?**

95

## Small Worlds

- \* **Determinação dos Caminhos mais Curtos**

- \* Pode existir mais do que um caminho mais curto. O algoritmo determina apenas um dos caminhos.
- \* Se a rede tiver mais do que uma componente conexa, não existem todos os caminhos e o algoritmo termina sem encontrar alguns caminhos.

96

## Small Worlds

- \* **Determinação dos Caminhos mais Curtos**
- \* Para redes com pesos associados às ligações existem outros algoritmos de determinação dos caminhos mais curtos.

97

## Small Worlds

- \* **Distância Social**
- \* Algumas redes apresentam caminhos longos, por exemplo, as redes de estradas e as redes de abastecimento.
- \* No entanto, verifica-se que as redes sociais apresentam, em geral, caminhos mais curtos com poucas ligações. Como exemplos, podem mencionar-se as redes de colaboração científica e as redes de actores.

98

## Small Worlds

- \* **Distância Social**

- \* Nestas redes as pessoas são representadas nos nodos.
- \* Uma ligação entre dois nodos representa uma colaboração científica (coautoria de um artigo científico) ou a participação no mesmo filme ou série.

99

## Small Worlds

- \* **Distância Social**

- \* No caso da colaboração científica, entre matemáticos, pode determinar-se a distância entre dois matemáticos ou entre um matemático e Paul Erdős em <https://mathscinet.ams.org/mathscinet/collaborationDistance.html>.
- \* (Paul Erdős foi um matemático Húngaro que publicou bastantes artigos científicos.)

100

## Small Worlds

- \* **Distância Social**

- \* No caso das redes de actores, há um jogo - *Six Degrees of Kevin Bacon*, disponível em [oracleofbacon.org](http://oracleofbacon.org) - que indica a distância de Kevin Bacon a outro ator ou entre dois atores, apresentando um caminho.
- \* Para obter estas distâncias, consideram-se apenas filmes.

101

## Small Worlds

- \* **Distância Social**

- \* Verifica-se que é difícil encontrar caminhos longos nestas redes e noutras redes reais.
- \* Por este motivo, estas redes são classificadas como **mundos pequenos** (*small worlds*).

102



## Small Worlds

- \* **Seis Graus de Separação**

- \* O nome do jogo *Six Degrees of Kevin Bacon* é baseado no conceito de seis graus de separação (*six degrees of separation*).
- \* Este conceito tem origem no facto de num mundo pequeno quaisquer dois elementos estão unidos por uma sequência de ligações com poucos elementos.
- \* Numa rede social, em geral, as distâncias são curtas e a média é ainda menor.

103

## Small Worlds

- \* **Seis Graus de Separação**

- \* O número seis foi proposto pelo autor Húngaro Frigyes Karinthy em "Cadeias", em 1929.
- \* Contudo, já no início do século XX, Marconi tinha uma ideia semelhante sobre distância social.
- \* Só na década de 60 do século XX se obteve a primeira evidência empírica de mundos pequenos.

104

## Small Worlds

- \* **Seis Graus de Separação**

- \* O psicólogo Stanley Milgram propôs uma experiência para medir a distância social entre estranhos.
- \* Solicitou a 160 habitantes do Nebraska e do Kansas que enviassem uma carta a um conhecido, com instruções de que carta deveria chegar a uma determinada pessoa do Massachusetts.
- \* Cada pessoa que recebia a carta deveria enviá-la a um conhecido seu.

105

## Small Worlds

- \* **Seis Graus de Separação**

- \* Apenas 42 cartas chegaram ao destino.
- \* Os comprimentos dos caminhos da rede associada às cartas que chegaram ao destino variavam entre 3 e 12 e a média foi pouco superior a 6, o que poderá ter originado a expressão "seis graus de separação".

106

## Small Worlds

- \* **Seis Graus de Separação**

- \* Esta experiência foi repetida com emails em 2003. Consideraram-se 18 destinatários em 13 países. Das mais de 24 000 cadeias iniciadas, apenas 384 ficaram completas.
- \* As cadeias completas apresentavam uma distância média de 4.
- \* Tendo em conta muitas cadeias interrompidas, os autores do estudo estimaram que a mediana da distância estaria entre 5 e 7.

107

## Small Worlds

- \* **Seis Graus de Separação**

- \* Mais recentemente, em 2011, um estudo realizado na Universidade de Milão, sobre o Facebook, permitiu concluir que as distâncias entre utilizadores ativos (várias centenas de milhão) apresentavam uma média de 4,74.

108

## Small Worlds

- \* **Seis Graus de Separação**
- \* Nos exemplos anteriores referiu-se a existência de distâncias pequenas.
- \* No entanto, o que pode ser considerado "pequeno"?
- \* Como se define "pequeno"?
- \* Esta definição deve ter em conta o número de nodos da rede.

109

## Small Worlds

- \* **Seis Graus de Separação**
- \* Pode dizer-se que a distância média é pequena se cresce muito lentamente com o número de nodos da rede.
- \* Usualmente compara-se a distância média com o valor do logaritmo (de base 10) do número de nodos, que é uma função que cresce muito lentamente.
- \* Considera-se então que a distância média é pequena se for próxima do valor do logaritmo de  $N$

$$\langle l \rangle \sim \log N$$

110

## Small Worlds

- \* **Seis Graus de Separação**

- \* Os caminhos curtos não são exclusivos das redes sociais (colaboração científica, redes de actores, Facebook, ...).
- \* A rede de tráfego aéreo, a *Wikipedia* e a *Web* também apresentam caminhos com distâncias pequenas.

111

## Small Worlds

- \* **Coeficientes de Clustering**

- \* Considere-se uma rede social. Se a Alexandra e a Beatriz são amigas do Pedro então existe a possibilidade de a Alexandra e de a Beatriz serem amigas.
- \* Pode mesmo dizer-se que há fortes possibilidades de um amigo de um dos meus amigos ser também meu amigo.
- \* Este fenómeno observa-se no *Linkedin*, *Facebook* e noutras redes (amizade, pessoas que conhecemos, colegas,...).

112

## Small Worlds

### \* Coeficientes de *Clustering*

- \* Numa rede social, podem observar-se diversos **triângulos** (*triangles*) - conjuntos de três nodos em que existe uma ligação entre cada par de nodos.
- \* A conectividade entre os nodos adjacentes de outros nodos é uma característica relevante da estrutura local da rede, porque indica como se agrupam os nodos.

113

## Small Worlds

### \* Coeficientes de *Clustering*

- \* O coeficiente de *clustering* de um nodo é a fracção de pares de nodos adjacentes desse nodo que estão ligados entre si.
- \* Equivalentemente, é igual ao rácio entre o número de triângulos que incluem o nodo e o número máximo de triângulos envolvendo o nodo que poderiam existir.

114

## Small Worlds

- \* **Coeficientes de Clustering**

- \* O coeficiente de clustering do nodo  $i$  —  $C(i)$  — é dado por

$$\frac{\tau(i)}{\tau_{max}} = \frac{2\tau(i)}{k_i(k_i - 1)}$$

- \*  $\tau(i)$  representa o número de triângulos envolvendo o nodo  $i$
- \*  $\tau_{max}$  representa o número máximo de triângulos envolvendo o nodo  $i$  que poderiam existir na rede.

115

## Small Worlds

- \* **Coeficientes de Clustering**

- \* Este número máximo é dado pelo número de subconjuntos com dois elementos do conjunto de nodos adjacentes de  $i$ .
- \* O coeficiente anterior está definido apenas para nodos com grau superior a 1.

116

## Small Worlds

- \* **Coeficientes de Clustering**

- \* O coeficiente de *clustering* médio é a média dos coeficientes de clustering dos nodos e é dado por

$$\langle C \rangle = \frac{\sum_{i:k_i>1} C(i)}{N_{k>1}}$$

- \* No cálculo desta média podem considerar-se apenas os nodos com grau superior a 1 ou todos os nodos da rede.

117

## Small Worlds

- \* **Coeficientes de Clustering**

- \* Para definir o coeficiente de *clustering* da rede, considerem-se as subredes conexas de dimensão três.
- \* Estas subredes são designadas por ternos conexas (*triplet*).

118



## Small Worlds

- \* **Coeficientes de Clustering**

- \* Nestas subredes podem existir duas ou três ligações, sendo designadas por ternos conexos abertos (*open triplets*) ou ternos conexos fechados (*closed triplets*).
- \* No caso de existirem três ligações, é possível identificar um triângulo.
- \* A cada triângulo estão associados três ternos conexos, cada terno conexo está centrado num nodo.

119

## Small Worlds

- \* **Coeficientes de Clustering**

- \* O coeficiente de *clustering* da rede é dado pelo rácio

$$C = \frac{\text{número de ternos conexos fechados}}{\text{número total de ternos conexos}}$$

- \* que é equivalente a

$$C = \frac{3 \times \text{número de triângulos}}{\text{número total de ternos conexos}}$$

120

## Small Worlds

- \* **Coeficientes de *Clustering***

- \* Ou ainda, equivalente a


$$C = \frac{\text{traço}(A^3)}{\sum_i k_i(k_i - 1)}$$

121

## Small Worlds

- \* **Coeficientes de *Clustering***

- \* **Ex. 6 g)**



122

## Small Worlds

### \* **Coeficientes de Clustering**

- \* Esta definição de coeficiente de clustering apenas se aplica a redes não orientadas.
- \* No caso de redes orientadas, será necessário definir em que consiste um triângulo, se é baseado numa relação de transitividade ou não. A escolha depende da rede em análise.

123

## Small Worlds

### \* **Coeficientes de Clustering**

- \* Um valor elevado, próximo de 1, indica a existência de muitos triângulos.
- \* As redes sociais apresentam coeficientes de clustering significativos.
- \* Isto deve-se ao facto de as pessoas conhecerem pessoas a partir dos seus contactos, obtendo-se assim triângulos.
- \* Este mecanismo é designado por **fecho triádico** (*triadic closure*).

124

# ANÁLISE DE REDES

## *Hubs e Heterogeneidade de Pesos*

Licenciatura em  
Ciência de Dados

1

1

## *Hubs*

- \* Em diversas redes, alguns nodos têm bastante mais ligações do que os restantes:
- \* aeroportos com muito mais ligações do que a maioria;
- \* pessoas com bastante mais visibilidade do que a maioria.
- \* Nestes casos, estamos perante heterogeneidade da rede.

2

2

1

## Hubs

- \* A importância de um nodo ou ligação de uma rede pode ser estimada determinando a sua centralidade.
- \* O grau de um nodo é uma das medidas de centralidade.
- \* Os hubs são nodos com grau elevado, bastante superior ao da maior parte dos restantes nodos da rede.
- \* A existência de *hubs* induz propriedades particulares nas redes.

3

3

## Hubs

- \* Medidas de Centralidade
  - \* Grau
  - \* Proximidade e Centralidade de Proximidade
  - \* Intermediação e Centralidade de Intermediação.

4

4

2

## Hubs

- \* **Grau**
- \* O grau de um nodo de uma rede não orientada é o número de ligações incidentes nesse nodo.
- \* O grau médio indica como, em média, os nodos de uma rede estão ligados entre si.
- \* Por se tratar de um valor médio, pode não ser representativo da distribuição de grau.

5

5

## Hubs

- \* **Proximidade e Centralidade de Proximidade**
- \* A **proximidade** (*closeness*) é uma medida de centralidade que mede o quão "próximo" está um nodo dos restantes.
- \* A proximidade de um nodo é baseada na soma das distâncias entre o nodo e cada um dos restantes.
- \* Se o total for reduzido então o nodo tem uma centralidade elevada, está próximo dos restantes.

6

6

3

# Hubs

- \* **Proximidade e Centralidade de Proximidade**
- \* A centralidade de proximidade (*closeness centrality*) é definida como o inverso da soma das distâncias entre o nodo e todos os restantes:

$$g_i = \frac{1}{\sum_{j \neq i} l_{ij}}$$

em que  $l_{ij}$  representa a distância de  $i$  para  $j$ , o comprimento do caminho mais curto entre  $i$  e  $j$ .

7

7

# Hubs

- \* **Proximidade e Centralidade de Proximidade**
  - \* Esta medida pode depender da dimensão da rede (número de nodos da rede).
  - \* Torna-se difícil comparar redes de diferentes dimensões.
  - \* Como alternativa, pode multiplicar-se esta medida por  $(N - 1)$  :
- $$\tilde{g}_i = \frac{N-1}{\sum_{j \neq i} l_{ij}} \quad \text{ou} \quad \tilde{g}_i = \frac{1}{\sum_{j \neq i} l_{ij} / (N-1)}$$
- \* O denominador representa a distância média entre o nodo  $i$  e os restantes nodos da rede.


8

8

# Hubs

## \* Proximidade e Centralidade de Proximidade

### \* Ex. 1



a) e b).

9

# Hubs

## \* Intermediação e Centralidade de Intermediação

- \* Muitos fenómenos são baseados em processos de difusão.
- \* Esta difusão pode ocorrer não diretamente, mas através de caminhos.
- \* Nós com grau pouco elevado podem ser relevantes em processos de difusão, se passam muitos caminhos mais curtos por estes nós.
- \* Para avaliar a intermediação dos nós, considera-se uma medida baseada no número de caminhos mais curtos.

10



# Hubs

- \* **Intermediação e Centralidade de Intermediação**
- \* Sejam  $\sigma_{hj}$  o número de caminhos mais curtos entre  $h$  e  $j$ ,  $\sigma_{hj}(i)$  o número destes caminhos que passam pelo nodo  $i$ . A **centralidade de intermediação** (*betweenness centrality*) de  $i$  é dada por:

$$b_i = \sum_{(h,j): h,j \neq i} \frac{\sigma_{hj}(i)}{\sigma_{hj}}$$

11

11

# Hubs

- \* **Intermediação e Centralidade de Intermediação**
- \* Esta medida é adequada quando o número de caminhos mais curtos dá uma boa aproximação da frequência de utilização do nodo, o que é comum, por exemplo, em redes de transportes.


12

12

# Hubs

## \* Intermediação e Centralidade de Intermediação

### \* Ex. 1 c)




13

13

# Hubs

## \* Medidas de Centralidade

### \* Ex. 5



a), b), c) e d).

14

14

## Hubs

- \* **Intermediação e Centralidade de Intermediação**
- \* A centralidade de intermediação normalizada de um nodo  $i$  obtém-se dividindo  $b_i$  por 
$$\frac{(N-1)(N-2)}{2}$$
- \* O número máximo de caminhos, entre nodos distintos de  $i$ , que passam pelo nodo  $i$ , é igual a 
$$\frac{(N-1)(N-2)}{2}$$

15

15

## Hubs

- \* **Intermediação e Centralidade de Intermediação**
- \* A centralidade de intermediação de uma ligação é a fracção de caminhos mais curtos que incluem esta ligação, de entre todos os caminhos mais curtos existentes na rede.


16

16

# Hubs

## \* Intermediação e Centralidade de Intermediação

### \* Exemplo



\* A centralidade de intermediação de (1,3) é  $4/15$ .

\* A centralidade de intermediação de (3,4) é  $9/15 = 0,6$ .


17

17

# Hubs

## \* Intermediação e Centralidade de Intermediação

### \* Ex. 5



e) Determine a medida de centralidade de intermediação para a ligação (4,5).

18

18

## Hubs

- \* **Intermediação e Centralidade de Intermediação**
- \* Ligações com uma centralidade de intermediação elevada frequentemente unem partes da rede que constituem comunidades.

19

19

## Hubs

- \* **Distribuição de Centralidade**
- \* Para redes de dimensão elevada, será necessário uma abordagem estatística para estudar a distribuição de grau.
- \* Podem considerar-se tabelas de frequências e representações gráficas, por exemplo histogramas.


20

20

10

# Hubs

## \* Distribuição de Centralidade Exemplo



21

21

# Hubs

## \* Distribuição de Centralidade Exemplo (continuação)


Grau	Frequências Absolutas	Frequências Relativas
1	0	0
2	3	0,375 (3/8)
3	4	0,5
4	1	0,125 (1/8)
		1

22

22

# Hubs

## \* Distribuição de Centralidade Exemplo (continuação)



23

# Hubs

- \* Distribuição de Centralidade
- \* Quando estão presentes ordens de grandeza muito diversas, podem considerar-se escalas logarítmicas.

24

24

# Hubs

- \* **Distribuição de Centralidade**
- \* **Heterogeneidade**
- \* A amplitude de variação na distribuição poderá dar uma ideia sobre a heterogeneidade.
- \* Uma representação gráfica da distribuição de grau com uma cauda longa ou pesada (*heavy-tailed*) revela heterogeneidade nos valores dos graus.
- \* Neste caso, muitos nodos têm poucos adjacentes enquanto que poucos nodos têm muitos adjacentes.

25

25

# Hubs

- \* **Distribuição de Centralidade**
- \* **Heterogeneidade**
- \* Nodos com grau bastante superior ao da maior parte dos restantes nodos da rede são designados por **hubs**.
- \* Para avaliar a heterogeneidade de uma rede, pode considerar-se o parâmetro

$$\kappa = \frac{\langle k^2 \rangle}{\langle k \rangle^2}.$$

26

26



# Hubs

- \* **Distribuição de Centralidade**
- \* **Heterogeneidade**
- \* Se o valor de  $\kappa$  está próximo de 1 então não há heterogeneidade, a distribuição de grau estará concentrada à volta de um determinado valor.
- \* Quando o valor de  $\kappa$  é bastante superior a 1, estamos perante *hubs*.


27

27

# Hubs

- \* **Distribuição de Centralidade**
- \* **Heterogeneidade**

Ex. 5



f) Determine o parâmetro de heterogeneidade.

28

28

# Hubs

- \* **Distribuição de Centralidade**
- \* **Heterogeneidade**
- \* Para redes orientadas, o estudo da heterogeneidade será feito considerando o grau incidente e o grau divergente.

29

29

# Hubs

- \* **Paradoxo da Amizade**
- \* Numa rede de dimensão  $N$ , quando se escolhe aleatoriamente um nodo, a probabilidade de o nodo escolhido ser o de maior grau é igual a  $1/N$ .
- \* No entanto, se se escolher aleatoriamente um nodo adjacente de um nodo escolhido ao acaso, a probabilidade de obter o nodo com maior grau aumenta.
- \* Designemos a escolha aleatória de nodos por primeiro método e o segundo procedimento de escolha de um nodo por segundo método.

30


30

15

# Hubs

- \* Paradoxo da Amizade

- \* Exemplo



- \* 5 é o nodo com maior grau (1/5 vs. 2/5).

31

31

# Hubs

- \* Paradoxo da Amizade

- \* Quando se considera o segundo método, em vez de se escolher um nodo, procuram-se ligações.

- \* Assim, quanto maior o grau de um nodo, maior será a probabilidade de ser o escolhido.

32

32

# Hubs

- \* **Paradoxo da Amizade**

- \* Se se generalizar o segundo método, passando diversas vezes de um nodo para os seus adjacentes, a probabilidade de se obter um *hub* aumenta.
- \* Em diversos contextos, a determinação de *hubs* pode ser necessária (para tentar interromper cadeias de transmissão, difundir mais rapidamente informação).

33

33

# Hubs

- \* **Paradoxo da Amizade**

- \* A escolha baseada nas ligações, em vez dos nodos, tem outra implicação.
- \* O grau médio é inferior à média dos graus dos nodos adjacentes (vizinhos).
- \* Pode ser enunciado como "Os nossos amigos têm, em média, mais amigos do que nós." (Paradoxo da Amizade)

34

34

## Hubs

- \* **Paradoxo da Amizade**
- \* Quando se calcula o grau médio dos nodos, o grau de cada nodo é considerado apenas uma vez.
- \* Quando se calcula a média dos graus médios dos nodos adjacentes, cada nodo é considerado tantas vezes quantas o seu grau.

35

35

## Hubs

- \* **Paradoxo da Amizade**
- \* Pode considerar-se que o cálculo das duas médias é baseado em amostragem.
- \* No primeiro caso, utiliza-se amostragem uniforme.
- \* No segundo caso, a cada nodo corresponde uma proporção baseada no seu grau.

36

36

# Hubs


- \* **Paradoxo da Amizade**
- \* Quando os graus dos nodos diferem pouco, as duas médias são aproximadas.
- \* Pelo contrário, quando existem nodos com grau bastante superior ao da maioria (existem *hubs*) a diferença entre as duas médias acentua-se.

37

37

# Hubs

- \* **Paradoxo da Amizade**
- \* **Ex. 5 g)**




38

38

# Hubs

\* Resolver Ex. 3 a) - c)



39

39

# Hubs

\* Ex. 2

Distribuição de Grau



40

40

20

# Hubs

- \* **Ultra-Small Worlds**
- \* Muitas redes reais são *small worlds* (qualquer par de nodos está ligado por um número reduzido de ligações).
- \* Em redes em que existem *hubs*, muitos caminhos mais curtos passam provavelmente por um ou mais *hubs* (porque estes nodos têm muitas ligações).
- \* A inclusão de *hubs* nos caminhos permite reduzir as distâncias.

41

41

# Hubs

- \* **Ultra-Small Worlds**
- \* Frequentemente, em redes com maior diferença entre o grau máximo e o grau mínimo (redes com *hubs*), as distâncias entre nodos são muito reduzidas.
- \* Esta propriedade é designada por *ultra-small worlds*.

42

42

21



## Hubs

- \* **Ultra-Small Worlds**
- \* Quando se comparam redes com o mesmo número de nodos e de ligações, com e sem *hubs*, espera-se que a distância média seja menor em redes com *hubs* do que em redes sem *hubs*.
- \* O Twitter é um exemplo de *ultra-small world*.

43

43

## Hubs

- \* **Web e Hubs**
- \* Como já foi referido, a Web pode ser representada numa rede orientada.
- \* A distribuição do grau incidente apresenta uma cauda longa ou pesada.
- \* Além disso, o parâmetro de heterogeneidade toma um valor elevado.
- \* Estas duas características indicam a presença de *hubs* de dimensão considerável.

44

44

# Hubs

- \* **Web e Hubs**
- \* A Web apresenta a estrutura de mundos ultra pequenos (*ultra-small worlds*), devido à presença de hubs.
- \* Por exemplo, considerando dados de 2012, constatou-se que na maior das componentes fortemente conexa, que incluía 1800 milhões de páginas, a distância média era inferior a 13.

45

45

# Hubs

- \* **Web e Hubs**
- \* A Wikipedia e os blogs também apresentam uma distribuição com cauda longa do grau incidente e da dimensão das componentes.
- \* A estrutura de mundos ultra pequenos (*ultra-small worlds*) também está presente nestas redes de informação.

46

46

# Hubs

- \* **Redes Scale-Free**

- \* Uma rede *scale-free* é uma rede cuja distribuição de grau segue uma lei de potência (*power law*).
- \* Trata-se de uma rede cuja distribuição de grau é bem representada ou bem aproximada por

$$k^{-\gamma}$$

( $p_k \sim k^{-\gamma}$ ) em que  $k$  representa os valores do grau.

47

47

# Hubs

- \* **Redes Scale-Free**

- \* É expectável que uma rede com esta propriedade tenha *hubs*.
- \* Por outro lado, pode provar-se que quanto maior for a dimensão da rede maior será o grau do nodo com grau máximo.

48

48

## Hubs

- \* **Robustez**
- \* Um sistema é robusto se a falha de alguma das suas componentes não afecta o seu funcionamento.
- \* Genericamente, a robustez depende de quais as componentes que falham e dos danos resultantes.

49

49

## Hubs

- \* **Robustez**
- \* Como se pode definir a robustez de uma rede?
- \* A robustez de uma rede pode ser avaliada tendo em conta as consequências da remoção de alguns nodos e das ligações incidentes nestes nodos.

50

50

25

## Hubs

- \* **Robustez**

- \* A remoção destes nodos pode não afectar a conectividade e o sistema resultante associado mantém-se em funcionamento.
- \* Ou pode deixar a rede desconexa e, consequentemente, o funcionamento do sistema será severamente comprometido.

51

51

## Hubs

- \* **Robustez**

- \* O teste *standard* à robustez consiste em determinar como a conectividade é afectada à medida que o número de nodos removidos aumenta.
- \* Para estimar o impacto da remoção de nodos, determina-se o rácio entre o número de nodos da componente gigante e o número original de nodos da rede.

52

52

## Hubs

- \* **Robustez**
- \* Se a rede se mantém conexa, o valor deste rácio diminui lentamente devido à redução do número de nodos na rede.
- \* Se, pelo contrário, a rede deixa de ser conexa, o valor do rácio reduz significativamente.

53

53

## Hubs


- \* **Robustez**
- \* A remoção pode dever-se a falhas (*failures*) ou ataques (*attacks*).
- \* No caso da remoção ser aleatória, devido a uma falha, espera-se que o número de *hubs* se mantenha significativo. Assim, a dimensão da componente gigante diminuirá lentamente.
- \* No caso de ataques, os *hubs* serão os alvos e a rede tornar-se-á rapidamente desconexa.

54

54

# Hubs

- \* Robustez
- \* Ex. 5 h), i)



55

55

# Hubs

- \* Robustez
- \* As redes reais são, em geral, robustas a falhas e vulneráveis a ataques, porque possuem *hubs*.

56

56

## Hubs

- \* **Decomposição da Rede (Core Decomposition)**
- \* Em redes de grande dimensão pode ser útil considerar apenas a parte mais densa (*core*).
- \* O grau dos nodos pode ser utilizado para dividir a rede em partes, designadas por conchas (*shells*), e baseadas na estrutura e localização periféricas da rede.

57

57

## Hubs

- \* **Decomposição da Rede (Core Decomposition)**
- \* Para obter a parte mais densa da rede, baseada no grau dos nodos, começa-se por remover os nodos com menor grau.
- \* O algoritmo de decomposição *k-core decomposition* é um algoritmo iterativo que começa por iniciar o valor de *k* a 0 e consiste nos seguintes passos:

58

58



# Hubs

## \* Decomposição da Rede (Core Decomposition)

- \* 1 - Remover recursivamente todos os nodos com grau igual a  $k$ , de forma que todos os restantes nodos (se existirem) tenham grau superior a  $k$ ;
- \* 2 - Os nodos removidos constituem a  $k$ -concha ( $k$ -shell) e os restantes nodos constituem o  $(k+1)$ -core, porque têm grau maior ou igual a  $k+1$ .
- \* 3 - Se não existem mais nodos, o algoritmo termina; caso contrário, incrementa-se  $k$  e volta-se ao passo 1.

Esta decomposição é bastante útil para remover os nodos periféricos.

59


59

# Hubs

## \* Decomposição da Rede (Core Decomposition)

### \* Exemplo

- \* O 2-core da seguinte rede




60

60

30

# Hubs

- \* Decomposição da Rede (Core Decomposition)
- \* Exemplo (Continuação)
- \* é




61

61

# Hubs

- \* Decomposição da Rede (Core Decomposition)
- \* Ex. 5 j)



62

62

## Heterogeneidade de Pesos

- \* A visualização de redes densas não é fácil.
- \* O seu estudo também pode ser difícil.
- \* Muitas das ligações de redes densas com pesos associados às ligações não são relevantes e poderão ser removidas.

63

63

## Heterogeneidade de Pesos

- \* Pode pensar-se em generalizar a decomposição de *core* estudada (que se baseia no grau dos nodos).
- \* Assim, as ligações com pesos inferiores a um valor escolhido seriam removidas.
- \* Este procedimento pode ser adequado em alguma situações.

64

64

## Heterogeneidade de Pesos

- \* Noutras, em que se verifica uma grande heterogeneidade, pode não ser indicado.
- \* Por exemplo, se a força de alguns nodos for bastante inferior ao da maior parte dos nodos, deve considerar-se outra escala para as ligações incidentes nestes nodos.

65

65

## Heterogeneidade de Pesos

- \* Assim, pode considerar-se, em vez de um valor absoluto, um valor relativo:
  - \* manter apenas uma percentagem das ligações incidentes num nodo (as com maior peso)
  - \* ou manter as ligações de maior peso que totalizem uma percentagem da força do nodo.

66

66

## Heterogeneidade de Pesos

- \* Estas escolhas não garantem que se mantenham as ligações mais relevantes.
- \* Outra alternativa consiste em determinar as ligações que têm associadas uma fracção desproporcional da força de cada nodo. Estas serão as ligações a manter.

67

67

## Heterogeneidade de Pesos

- \* **"Espinha Dorsal" da Rede (Network Backbone)**
- \* Sejam  $i$  um nodo da rede,  $k_i$  e  $s_i$  o seu grau e a sua força, respectivamente.
- \* Seja ainda  $\alpha$  o nível de significância escolhido.
- \* Cada ligação será avaliada considerando que os pesos das ligações incidentes em  $i$  se distribuem aleatoriamente pelas  $k_i$  ligações e que a força de  $i$  é  $s_i$ .

68

68

## Heterogeneidade de Pesos

- \* **"Espinha Dorsal" da Rede (Network Backbone)**
- \* Assumindo esta hipótese, a probabilidade da ligação  $(i, j)$  ter peso igual ou superior a  $w_{ij}$  é dada por

$$p_{ij} = \left(1 - \frac{w_{ij}}{s_i}\right)^{k_i-1}$$

- \* Se  $p_{ij} < \alpha$  então mantém-se a ligação. Caso contrário, a ligação é removida.

69

# ANÁLISE DE REDES

## Redes Aleatórias

Licenciatura em  
Ciência de Dados

1

1

## Redes Aleatórias

- \* Muitas redes reais partilham um conjunto de propriedades:
  - \* os caminhos mais curtos entre dois nodos têm poucas ligações;
  - \* têm muitos triângulos, tendo por isso coeficientes de *clustering* elevados;
  - \* apresentam heterogeneidade quando se consideram os graus dos nodos e os pesos associados às ligações.

2

2

1

## Redes Aleatórias

- \* Paul Erdős e Alfréd Rényi iniciaram o estudo da Teoria de Grafos Aleatórios, para estudar como surgem estas propriedades.
- \* Este estudo é baseado nas redes aleatórias, também conhecidas como redes de Erdős-Rényi.

3

3

## Redes Aleatórias

- \* Uma rede de Erdős-Rényi é obtida escolhendo o número de nodos ( $N$ ) e o número de ligações ( $L$ ).
- \* Para escolher as ligações, geram-se aleatoriamente  $L$  pares de nodos.

4

4

2



## Redes Aleatórias

- \* Outras redes aleatórias, propostas por E. N. Gilbert, podem ser obtidas escolhendo o número de nodos e uma probabilidade de inclusão de cada ligação ( $p$ ).

5

5

## Redes Aleatórias

- \* Neste caso, as redes serão obtidas aplicando o seguinte procedimento:
  - \* 1 - seleccione-se um par de nodos  $(i, j)$ ;
  - \* 2 - gere-se um número aleatório  $r$ , entre 0 e 1.  
Se  $r < p$  então inclui-se a ligação  $(i, j)$ ;
  - \* 3 - repetem-se os passos 1 e 2 para todos os pares de nodos.

6

6

3

## Redes Aleatórias

- \* A aplicação deste procedimento, diversas vezes, para valores fixos de  $N$  e  $p$  pode gerar redes com diferentes números de ligações.
- \* Contudo, para valores de  $N$  suficientemente grandes, espera-se que o número de ligações seja aproximado.

7

7

## Redes Aleatórias

- \* Suponha agora que se está a gerar uma rede aleatória.
- \* Inicialmente a rede é constituída apenas por nodos.
- \* À medida que se adicionam ligações, pares de nodos são ligados.
- \* Após a introdução das primeiras ligações, a rede é composta por subredes de pequena dimensão.

8

8

4

## Redes Aleatórias

- \* Quando se forma a componente gigante?
- \* Erdős e Rényi descobriram que a componente gigante forma-se quando  $\langle k \rangle = 1$ .
- \* A configuração da rede muda repentinamente quando  $\langle k \rangle$  passa de um valor inferior a 1 para igual a 1.
- \* Por outro lado, a dimensão desta componente gigante cresce rapidamente com o aumento do grau médio (para valores superiores a 1).
- \* Ver NetLogo Giant Component

9

9

## Redes Aleatórias

- \* **Densidade das Redes Aleatórias**
- \* Considere-se o método de geração de uma rede aleatória baseado na escolha do número de nodos e da probabilidade de inclusão de cada ligação (Modelo de Gilbert).
- \* Este processo de geração de uma rede aleatória é semelhante à experiência de lançar repetidas vezes uma moeda.

10

10

5

## Redes Aleatórias

- \* **Densidade das Redes Aleatórias**
- \* Suponha-se que  $p$  representa a probabilidade de obter uma cara.
- \* O número esperado de caras obtidas será dado por  $pn$ , em que  $n$  representa o número de lançamentos.

11

11

## Redes Aleatórias

- \* **Densidade das Redes Aleatórias**
- \* No caso da rede aleatória, o número de lançamentos corresponde a

$$\binom{N}{2} = \frac{N(N-1)}{2}$$

que representa o número máximo de ligações de uma rede não orientada com  $N$  nodos.

12

12

# Redes Aleatórias

- \* **Densidade das Redes Aleatórias**

- \* Então:

$$\langle L \rangle = \frac{pN(N-1)}{2}.$$

- \* Atendendo à expressão para o grau médio, tem-se:

$$\langle k \rangle = \frac{2\langle L \rangle}{N} = p(N-1).$$

13

13

# Redes Aleatórias

- \* **Densidade das Redes Aleatórias**

- \* Além disso, a densidade será dada por:

$$d = \frac{\langle L \rangle}{L_{max}} = \frac{pN(N-1)/2}{N(N-1)/2} = p.$$

- \* Como as redes reais são esparsas, uma rede aleatória adequada para o estudo de redes reais terá associada uma probabilidade pequena.

14

14

## Redes Aleatórias

- \* **Distribuição de Grau das Redes Aleatórias**
- \* A distribuição de grau de uma rede aleatória será determinada pelo cálculo das probabilidades de um qualquer nodo da rede ter  $k$  adjacentes.
- \* Seja  $i$  um nodo qualquer de uma rede com  $N$  nodos. Qualquer um dos restantes  $N - 1$  nodos pode ser adjacente de  $i$ .

15

15

## Redes Aleatórias

- \* **Distribuição de Grau das Redes Aleatórias**
- \* Para que cada um dos restantes nodos seja adjacente de  $i$ , é necessário que exista uma ligação entre  $i$  e o nodo.
- \* No processo de geração da rede aleatória, a decisão de incluir uma ligação é independente da decisão de incluir ou não incluir cada uma das restantes.

16

16

# Redes Aleatórias

## \* Distribuição de Grau das Redes Aleatórias

- \* Se a probabilidade de dois nodos serem adjacentes for  $p$  então a probabilidade de um nodo ter grau igual a  $k$  é dada por:

$$P(k) = \binom{N-1}{k} p^k (1-p)^{N-1-k}$$

17

17

# Redes Aleatórias

## \* Distribuição de Grau das Redes Aleatórias

- \* Trata-se da distribuição Binomial, de parâmetros  $(N-1)$  e  $p$ , que tem valor esperado dado por  $(N-1)p$ .
- \* Assim, para valores elevados de  $N$  e com  $Np$  constante (e não muito pequeno) pode considerar-se que  $Np \approx \langle k \rangle$ .

18

18

## Redes Aleatórias

- \* **Distribuição de Grau das Redes Aleatórias**
- \* Na distribuição Binomial os valores que acumulam maior probabilidade estão concentrados à volta do valor esperado.
- \* Além disso, o gráfico que representa as probabilidades não apresenta uma cauda longa.
- \* Podemos então concluir que nas redes aleatórias não se verifica a presença de hubs.

19

19

## Redes Aleatórias

- \* **Caminhos mais curtos**
- \* Já se viu que os graus dos nodos de uma rede aleatória não diferem muito.
- \* Para estudar a existência de caminhos mais curtos com poucas ligações, considere-se uma rede conexa em que todos os nodos têm grau  $k$ .

20

20

10



## Redes Aleatórias

- \* **Caminhos mais curtos**
- \* Considere-se ainda um nodo qualquer da rede.
- \* Este nodo está:
  - \* a uma distância igual a 1 de  $k$  nodos;
  - \* a uma distância igual a 2 de  $k(k - 1)$  nodos;
  - \* a uma distância igual a 3 de  $k(k - 1)^2$  nodos.

21

21

## Redes Aleatórias

- \* **Caminhos mais curtos**
- \* Assim, o nodo está a uma distância igual a  $l$  de  $k(k - 1)^{l-1}$  nodos.
- \* O valor real de nodos pode ser inferior a  $k(k - 1)^{l-1}$  porque alguns dos nodos a uma distância não superior a  $l$  podem estar repetidos.

22

22

## Redes Aleatórias

- \* **Caminhos mais curtos**
- \* Se o valor de  $k$  não for muito pequeno então pode considerar-se  $k \approx k - 1$  e a estimativa para o número de nodos a uma distância igual a  $l$  será aproximada por  $k^l$ .
- \* Seja  $l_{max}$  a maior das distâncias - o diâmetro da rede -, então esta distância permite alcançar todos os nodos da rede e

$$k^{l_{max}} = N.$$

23

23

## Redes Aleatórias

- \* **Caminhos mais curtos**
- \* Tem-se então  $l_{max} = \log_k N = \frac{\log N}{\log k}$ .
- \* Dado que os graus dos nodos de uma rede aleatória não diferem muito, a expressão anterior constitui uma boa aproximação quando se tomam valores de  $k$  em torno de  $\langle k \rangle$ .

24

24

## Redes Aleatórias

- \* **Caminhos mais curtos**
- \* Como a função logarítmica cresce lentamente, o valor de  $l_{max}$  cresce lentamente quando  $N$  aumenta.
- \* Conclui-se então que nas redes aleatórias existem caminhos mais curtos com poucas ligações.

25

25

## Redes Aleatórias

- \* **Caminhos mais curtos**
- \* Considere-se uma rede aleatória para representar a rede mundial de contactos sociais.
- \* Com base no número de Dunbar, considere-se ainda que o grau médio é 150.
- \* Tem-se que  $150^5 = 75\,937,5$  milhões, que é nove vezes superior à população mundial.
- \* Este resultado é compatível com a experiência de Stanley Milgram.

26

26

## Redes Aleatórias

- \* **Coeficiente de *Clustering***

- \* O coeficiente de *clustering* de um nodo mede a fracção de nodos adjacentes unidos por uma ligação.
- \* Uma ligação entre dois nodos adjacentes forma um triângulo.

27

27

## Redes Aleatórias

- \* **Coeficiente de *Clustering***

- \* Numa rede aleatória, gerada considerando o número de nodos e uma probabilidade  $p$  de inclusão de cada ligação, a probabilidade de dois nodos adjacentes estarem unidos é igual a  $p$ .
- \* O coeficiente de *clustering* de cada nodo pode não ser exatamente igual a  $p$ .
- \* Contudo, espera-se que a média dos coeficientes de *clustering* dos nodos seja bem aproximada por  $p$ .

28

28

## Redes Aleatórias

- \* **Coeficiente de *Clustering***

- \* Se a rede aleatória for esparsa então o valor de  $p$  será pequeno e a rede terá poucos triângulos.
- \* Se se aumentar o valor da probabilidade então o número de triângulos aumenta, assim como a densidade da rede (o que não será realista para simular redes sociais reais).

29

29

## Redes Aleatórias

- \* **Mundos Pequenos (*Small Worlds*)**

- \* Com vista a obter redes aleatórias com coeficientes de *clustering* mais elevados, Duncan J. Watts e Steven H. Strogatz desenvolveram o Modelo de Mundos Pequenos (*small-world model*), também conhecido como modelo Watts-Strogatz.

30

30

## Redes Aleatórias

- \* **Mundos Pequenos (*Small Worlds*)**
- \* Começaram por gerar uma rede em que cada nodo está ligado aos 4 nodos mais próximos. Esta rede apresenta um coeficiente de *clustering* de 0,5.
- \* Contudo, a distância média não é pequena, devido às distâncias entre os nodos mais afastados entre si.

31

31

## Redes Aleatórias

- \* **Mundos Pequenos (*Small Worlds*)**
- \* Para reduzir a distância média, algumas ligações da rede serão substituídas. Esta substituição consiste em manter um dos nodos (um dos extremos da ligação) e modificar o outro nodo.
- \* A probabilidade de substituir cada ligação será representada por  $p$ .

32

32

## Redes Aleatórias

- \* **Mundos Pequenos (*Small Worlds*)**
- \* A substituição das ligações irá reduzir o número de triângulos, mas reduzirá algumas distâncias e a distância média.
- \* Quais os valores de  $p$  que permitem reduzir a distância média sem diminuir drasticamente o coeficiente de *clustering*?

33

33

## Redes Aleatórias

- \* **Mundos Pequenos (*Small Worlds*)**
- \* A probabilidade deve ser pequena para manter muitos triângulos.
- \* Por exemplo, alguns testes sugerem que valores entre 0,01 e 0,1 permitem reduzir a distância média e manter um número significativo de triângulos.
- \* Ver NetLogo Small Worlds<sub>34</sub>

34

17

## Redes Aleatórias

- \* **Mundos Pequenos (*Small Worlds*)**
- \* Outra possibilidade para a substituição de cada ligação consiste em escolher aleatoriamente os dois nodos unidos pela ligação, não mantendo nenhum dos nodos iniciais.
- \* Em vez de substituir ligações, podem ser adicionadas ligações escolhidas ao acaso.

35

35

## Redes Aleatórias

- \* **Mundos Pequenos (*Small Worlds*)**
- \* Também podem ser consideradas outras configurações iniciais. Por exemplo, uma grelha em que os nodos internos têm grau igual a 6 e os nodos na fronteira têm grau igual a 2, 3 ou 4.
- \* O modelo Watts-Strogatz não gera redes com *hubs*.

36

36



## Redes Aleatórias

- \* **Modelo de Configuração (*Configuration Model*)**
- \* Dada uma sequência, será possível gerar uma rede em que os graus dos nodos são os elementos da sequência?
- \* Para que exista uma rede nestas condições, a soma dos elementos da sequência terá que ser um número par.

37

37

## Redes Aleatórias

- \* **Modelo de Configuração (*Configuration Model*)**
- \* Uma solução simples é dada pelo Modelo de Configuração (*Configuration Model*).
- \* Suponha que se tem um conjunto de nodos e uma sequência que representa os graus dos nodos.

38

38

## Redes Aleatórias

- \* **Modelo de Configuração (*Configuration Model*)**
- \* Em cada nodo, desenha-se um número de linhas incidentes (*stubs*) igual ao grau do nodo.
- \* Estas linhas não representam ligações porque incidem apenas num nodo.

39

39

## Redes Aleatórias

- \* **Modelo de Configuração (*Configuration Model*)**
- \* O modelo consiste em:
  - \* 1 - escolher aleatoriamente um par de linhas;
  - \* 2 - ligar as duas linhas escolhidas, obtendo-se uma ligação.
- \* Este procedimento é repetido até todas as linhas ficarem unidas.

40

40

20

## Redes Aleatórias

- \* **Modelo de Configuração (*Configuration Model*)**
- \* O modelo pode originar soluções que apresentem algumas desvantagens: mais do que uma ligação entre o mesmo par de nodos e existência de lacetes (*loops*).

41

41

## Redes Aleatórias

- \* **Modelo de Configuração (*Configuration Model*)**
- \* Este modelo pode ser utilizado para verificar se uma propriedade de uma rede é consequência da distribuição de grau.
- \* Se a propriedade da rede em estudo também estiver presente em todas as redes geradas pelo modelo então a propriedade resulta da distribuição de grau.

42

42

21

## Redes Aleatórias

- \* **Modelo de Configuração (*Configuration Model*)**
- \* Para assegurar a validade desta conclusão, o modelo terá que gerar todas as redes com a distribuição de grau pretendida.
- \* Por exemplo, pretende-se averiguar se o coeficiente de *clustering* da rede resulta da distribuição de grau.

43

43

## Redes Aleatórias

- \* **Modelo de Configuração (*Configuration Model*)**
- \* Utilizando o Modelo de Configuração (*Configuration Model*) obtêm-se todas as redes com a distribuição de grau pretendida.
- \* Determina-se o coeficiente de *clustering* de cada uma das redes obtidas e verifica-se se é igual ao da rede inicial.

44

44

22

## Redes Aleatórias

- \* **Modelo de Configuração (*Configuration Model*)**
- \* Os Modelos Aleatórios Exponenciais (*Exponential Random Models*) permitem obter redes com outras propriedades ou com conjuntos de propriedades (por exemplo, redes com determinado coeficiente médio de clustering e determinada densidade).

45

45

## Redes Aleatórias

- \* **Ligação Preferencial (*Preferential Attachment*)**
- \* Todas as redes já consideradas são redes estáticas (*static networks*), porque o número de nodos não sofre alterações durante o processo de geração, apenas se acrescentam ou substituem ligações.

46

46

## Redes Aleatórias

- \* **Ligação Preferencial (*Preferential Attachment*)**
- \* Usualmente, as redes reais são dinâmicas (*dynamic networks*), no sentido em que nodos e ligações podem ser acrescentados ou removidos.
- \* A Web, a Wikipedia, o Facebook são alguns exemplos de redes dinâmicas. Apesar de algumas remoções, a dimensão destas redes tem crescido.

47

47

## Redes Aleatórias

- \* **Ligação Preferencial (*Preferential Attachment*)**
- \* Os modelos dinâmicos tipicamente incorporam alguma forma de crescimento da rede.
- \* Começa-se com uma configuração inicial, frequentemente considera-se uma clique de pequena dimensão (uma clique é uma rede ou subrede completa).
- \* Depois acrescentam-se os nodos um a um.

48

48

## Redes Aleatórias

- \* **Ligação Preferencial (*Preferential Attachment*)**
- \* Cada novo nodo é unido aos nodos já existentes de acordo com uma regra, que caracteriza o modelo.
- \* As redes aleatórias e modelos já estudados caracterizam-se pela falta de *hubs*, porque a probabilidade de uma ligação ser escolhida não difere da probabilidade associada a qualquer outra ligação.

49

49

## Redes Aleatórias

- \* **Ligação Preferencial (*Preferential Attachment*)**
- \* O próximo modelo procura gerar redes com *hubs*.
- \* Para tal, os novos nodos serão ligados aos nodos existentes, privilegiando as ligações a alguns dos nodos.
- \* Este mecanismo é designado por ligação preferencial (*preferential attachment*).

50

50

25

## Redes Aleatórias

- \* **Ligação Preferencial (*Preferential Attachment*)**
- \* O mecanismo privilegia as ligações a nodos com maior grau.
- \* Este mecanismo baseia-se no princípio: quanto mais se tem, mais se recebe.
- \* O método de ligação preferencial (*preferential attachment*) mais conhecido para redes foi proposto por Barabási e Albert, sendo designado por modelo de Barabási-Albert ou modelo BA.

51

51

## Redes Aleatórias

- \* **Ligação Preferencial (*Preferential Attachment*)**
- \* Começa-se com uma rede completa com  $m_0$  nodos. Cada iteração consiste em dois passos:
  - \* 1 - Adiciona-se um novo nodo  $i$  à rede com  $m \leq m_0$  ligações. O parâmetro  $m$  representa o grau médio da rede inicial.
  - \* 2 - A probabilidade de unir o novo nodo a um nodo  $j$  já existente é dada por
 
$$\frac{\text{grau de } j}{\text{soma dos graus dos nodos}}.$$

52

52



## Redes Aleatórias

- \* **Ligação Preferencial (*Preferential Attachment*)**
- \* O número de iterações realizadas é escolhido de forma a obter o número de nodos pretendidos.
- \* A aplicação deste método começa com graus iguais.
- \* A introdução de novos nodos e de novas ligações leva ao aumento dos graus de alguns nodos.
- \* Desde as primeiras iterações, o grau dos primeiros nodos será maior do que o dos nodos introduzidos posteriormente.

53

53

## Redes Aleatórias

- \* **Ligação Preferencial (*Preferential Attachment*)**
- \* Os nodos com maior grau têm maior probabilidade de serem escolhidos, logo o seu grau tende a aumentar bastante mais do que o dos restantes nodos.
- \* Assim, surgem a heterogeneidade e os *hubs*.

54

54

27

## Redes Aleatórias

- \* **Ligação Preferencial (*Preferential Attachment*)**
- \* No modelo Ligação Preferencial (*preferential attachment*), a escolha dos nodos adjacentes de cada novo nodo, com base no grau dos nodos já existentes, é relevante para a obtenção de *hubs*.
- \* No caso de a escolha dos nodos adjacentes ser aleatória, sem ter em conta o grau, observar-se-ia um crescimento da rede sem heterogeneidade.

55

55

## Redes Aleatórias

- \* **Ligação Preferencial (*Preferential Attachment*)**
- \* O método Ligação Preferencial (*preferential attachment*) foi utilizado para modelar a população das cidades, a concentração de riqueza individual, a dimensão de empresas, a produção científica e outros fenómenos.
- \* Ver NetLogo Preferential Attachment.

56

56

## Redes Aleatórias

- \* **Ligação Preferencial (*Preferential Attachment*)**
- \* O modelo Ligação Preferencial apresenta um conjunto de desvantagens:
  - \* o padrão da distribuição de grau não se altera qualquer que seja a escolha dos parâmetros;
  - \* os *hubs* pertencem ao conjunto dos primeiros nodos; nenhum dos nodos acrescentados a partir de determinada iteração será um *hub*;
  - \* não forma muitos triângulos;

57

57

## Redes Aleatórias

- \* **Ligação Preferencial (*Preferential Attachment*)**
- \* O modelo Ligação Preferencial apresenta um conjunto de desvantagens:
  - \* só se adicionam nodos e ligações e não há remoções de nodos nem de ligações;
  - \* forma uma rede conexa.

58

58

# Redes Aleatórias

## \* Outros Modelos

- \* Uma extensão do modelo anterior utiliza uma potência do grau, deixando a preferência de ser linear. Assim, a probabilidade anterior pode ser substituída por

$$\frac{k_j^\alpha}{\sum_l k_l^\alpha}$$

59

59

# Redes Aleatórias

## \* Outros Modelos

- \* Se o valor de  $\alpha$  for inferior a 1 então as probabilidades não crescem na mesma proporção que os graus e os *hubs* tendem a desaparecer.
- \* Se, pelo contrário, o valor de  $\alpha$  for superior a 1, então os nodos com maior grau acumulam mais ligações muito mais rapidamente. Assim, m nodos serão adjacentes da maioria dos nodos.

60

60

30

# Redes Aleatórias

## \* Outros Modelos

- \* Pode concluir-se que o modelo Ligação Preferencial está dependente da preferência linear (o expoente dos graus é igual a 1) para gerar diversos *hubs*. Esta é outra desvantagem do modelo.

61

61

# Redes Aleatórias

## \* Outros Modelos

### \* *Attractiveness Model*

- \* Outra variante do modelo Ligação Preferencial modifica a probabilidade adicionando uma constante  $A$  aos graus dos nodos. A probabilidade será dada por

$$\frac{A + k_j}{\sum_l (A + k_l)}$$

62

62

31

## Redes Aleatórias

- \* **Outros Modelos**
- \* ***Attractiveness Model***
- \* O parâmetro  $A$  é positivo e é designado por parâmetro de atratividade.
- \* A ideia consiste em escolher nodos com base, não apenas no grau, mas também na sua atratividade (por exemplo, citações de obras).

63

63

## Redes Aleatórias

- \* **Outros Modelos**
- \* ***Attractiveness Model***
- \* Ao contrário do modelo Ligação Preferencial, este modelo pode ser aplicado a configurações iniciais com nodos com grau nulo, redes orientadas e permite obter diversas distribuições de grau.
- \* São vantagens face ao modelo Ligação Preferencial.

64

64

# Redes Aleatórias

- \* **Outros Modelos**

- \* ***Fitness Model***

- \* O "Fitness Model", proposto por Bianconi e Barabási, considera uma modificação no cálculo das probabilidades.
- \* Considere-se uma função que toma valores para cada um dos nodos.

65

65

# Redes Aleatórias

- \* **Outros Modelos**

- \* ***Fitness Model***

- \* O grau de cada nodo é multiplicado pelo valor da função para o nodo. O valor da função traduz o apelo do nodo.
- \* A probabilidade será dada por:

$$\frac{n_j k_j}{\sum_l (n_l k_l)}$$

66

66

33

## Redes Aleatórias

- \* **Outros Modelos**

- \* ***Fitness Model***

- \* Quanto maior for o valor, maior será o apelo. A função é designada por função de *fitness*.
- \* Este modelo permite obter diversos *hubs*, se os valores da função forem limitados.
- \* Os valores da função podem permitir a competição entre os nodos iniciais e os novos nodos.

67

67

## Redes Aleatórias

- \* **Outros Modelos**

- \* ***Fitness Model***

- \* Como exemplos de aplicação pode referir-se a *Web*, a *Wikipedia* e publicações científicas. As páginas e os artigos com mais ligações, ou mais citados, não são necessariamente os mais antigos.

68

68



## Redes Aleatórias

- \* **Outros Modelos**
- \* ***Fitness Model***
- \* Os valores da função não sofrem alterações ao longo do tempo, o que pode constituir uma desvantagem do método.

69

69

## Redes Aleatórias

- \* **Outros Modelos**
- \* **Modelo Passeio Aleatório (*Random Walk Model*)**
- \* As redes geradas pelo modelo BA apresentam coeficientes de *clustering* reduzidos, porque a probabilidade de um nodo receber uma ligação é proporcional ao seu grau e não tem em conta a existência de nodos adjacentes.

70

70

# Redes Aleatórias

- \* **Outros Modelos**
- \* **Modelo Passeio Aleatório (Random Walk Model)**
- \* Para aumentar o número de triângulos, é necessário um mecanismo que favoreça a introdução de ligações entre nodos adjacentes.

71

71

# Redes Aleatórias

- \* **Outros Modelos**
- \* **Modelo Passeio Aleatório (Random Walk Model)**
- \* A formação de triângulos resultante da adição de uma ligação é designada por **fecho triádico** (*triadic closure*) e é um dos mecanismos mais relevante para a formação de ligações numa rede social.

72

72

# Redes Aleatórias

- \* **Outros Modelos**
- \* **Modelo Passeio Aleatório (Random Walk Model)**
- \* Vamos considerar a implementação mais intuitiva deste mecanismo, que é designada por **Modelo Passeio Aleatório** (*random walk model*).

73

73

# Redes Aleatórias

- \* **Outros Modelos**
- \* **Modelo Passeio Aleatório (Random Walk Model)**
- \* A ideia consiste em unir um novo nodo não só a um já existente mas também a um ou mais nodos adjacentes deste último.

74

74

## Redes Aleatórias

- \* **Outros Modelos**
- \* **Modelo Passeio Aleatório (Random Walk Model)**
- \* Considere-se uma rede qualquer de dimensão pequena. Cada iteração consiste nos passos:
  - \* 1 - Um novo nodo  $i$  é acrescentado à rede com  $m > 1$  ligações;

75

75

## Redes Aleatórias

- \* **Modelo Passeio Aleatório (Random Walk Model)**
- \* 2 - A primeira ligação será  $(i, j)$  em que  $j$  é um nodo já existente, escolhido aleatoriamente;
- \* 3 - Cada uma das restantes ligações une  $i$  a um dos adjacentes de  $j$  com probabilidade  $p$  ou une  $i$  a um nodo escolhido aleatoriamente com probabilidade  $1 - p$ .

76

76

## Redes Aleatórias

- \* **Modelo Passeio Aleatório (Random Walk Model)**
- \* O número de triângulos formados depende da probabilidade  $p$  considerada.
- \* Se esta probabilidade não for demasiado pequena, este modelo também vai gerar *hubs*.
- \* A probabilidade de um nodo receber ligações será proporcional ao seu grau, como no modelo BA.

77

77

## Redes Aleatórias

- \* **Modelo Passeio Aleatório (Random Walk Model)**
- \* Contudo, os novos nodos não escolhem os seus adjacentes com base no grau. A escolha do primeiro adjacente de cada novo nodo é aleatória.
- \* O fecho triádico induz a ligação preferencial.

78

78

## Redes Aleatórias

- \* **Modelo Passeio Aleatório (Random Walk Model)**
- \* Este modelo foi proposto em 2003.
- \* Contudo, em 1973, Mark S. Granovetter publicou o artigo "*The strength of weak ties*", em que estabeleceu uma relação estreita entre três componentes fundamentais das redes sociais: triângulos, peso das ligações e comunidades.

79

79

## Redes Aleatórias

- \* **Modelo Passeio Aleatório (Random Walk Model)**
- \* Introduziu o princípio do fecho triádico forte para explicar a formação das ligações nas redes sociais.

80

80

## Redes Aleatórias

- \* **Modelo Passeio Aleatório (Random Walk Model)**
- \* Neste artigo, o sociólogo argumentou que ligações fortes estão presentes em comunidades sociais, enquanto que as ligações fracas unem comunidades sociais.
- \* Estas ligações fracas permitem a circulação de "informação" na rede.

81

81

## Redes Aleatórias

- \* **Modelo Cópia (Copy Model)**
- \* O modelo Cópia consiste numa variante do modelo Passeio Aleatório, em que cada nodo é ligado a um nodo escolhido aleatoriamente ou a algum (ou a alguns) dos seus adjacentes.

82

82

## Redes Aleatórias

- \* **Modelo Cópia (Copy Model)**
- \* O modelo Cópia procura modelar cenários em que muitos triângulos podem resultar de cópias de contactos.

83

83

## Redes Aleatórias

- \* **Modelo Cópia (Copy Model)**
- \* Como exemplos, podem referir-se:
  - \* duplicação de genes (as cópias vão interagir com as mesmas proteínas);
  - \* conhecimento de novas obras a partir de listas bibliográficas ou lista de obras da mesma colecção;

84

84



## Redes Aleatórias

- \* **Modelo Cópia (Copy Model)**
- \* Como exemplos, podem referir-se:
  - \* criação de conteúdos na Web e cópia das hiperligações.
- \* A escolha entre um nodo e alguns dos seus adjacentes permite obter hubs mas o número de triângulos é reduzido.

85

85

## Redes Aleatórias

- \* **Modelo Ordenação (Rank Model)**
- \* No modelo Ligação Preferencial, frequentemente designado por BA, a escolha das ligações dos novos nodos é baseada no grau dos restantes nodos.
- \* Este modelo requer o conhecimento dos valores absolutos dos graus.

86

86

## Redes Aleatórias

- \* **Modelo Ordenação (Rank Model)**
- \* O modelo Ordenação permite considerar outras propriedades, além do grau.
- \* Baseia-se numa ordenação dos nodos considerando a propriedade escolhida.

87

87

## Redes Aleatórias

- \* **Modelo Ordenação (Rank Model)**
- \* O modelo pode começar com uma qualquer rede de pequena dimensão com  $m_0$  nodos.
- \* Uma propriedade dos nodos (grau, idade, ...) é escolhida para ordenar os nodos.

88

88

## Redes Aleatórias

- \* **Modelo Ordenação (Rank Model)**
- \* Cada iteração consiste nos passos:
  - \* 1 - Todos os nodos são ordenados com base na propriedade. Atribuem-se os valores  $R = 1, 2, 3, \dots$  aos nodos. O nodo  $l$  da lista ordenada recebe  $R = l$ .

89

89

## Redes Aleatórias

- \* **Modelo Ordenação (Rank Model)**
- \* Cada iteração consiste nos passos:
  - \* 2 - Adiciona-se um novo nodo  $i$  à rede com  $m \leq m_0$  novas ligações.

90

90

45

## Redes Aleatórias

- \* **Modelo Ordenação (Rank Model)**
- \* Cada iteração consiste nos passos:
  - \* 3 - A probabilidade de unir o novo nodo a um nodo  $j$  já existente é dada por

$$\frac{R_j^{-\alpha}}{\sum_l R_l^{-\alpha}}$$

em que  $\alpha > 0$  é um parâmetro.

91

91

## Redes Aleatórias

- \* **Modelo Ordenação (Rank Model)**
- \* Os nodos poderão ter que ser reordenados após cada iteração, se a propriedade escolhida depender das novas ligações adicionadas.
- \* Por exemplo, a escolha do grau obriga a reordenar os nodos.

92

92

## Redes Aleatórias

- \* **Modelo Ordenação (Rank Model)**

- \* Um nodo nas primeiras posições da lista ordenada terá maior probabilidade de receber uma nova ligação do que um dos nodos nas últimas posições da lista ordenada.
- \* Se os nodos tiverem sido ordenados pelo seu grau, os nodos com maior grau terão probabilidades associadas mais elevadas do que os com menor grau.

93

93

## Redes Aleatórias

- \* **Modelo Ordenação (Rank Model)**

- \* No entanto, a probabilidade depende da posição na ordenação e não será proporcional aos graus.
- \* A taxa de decréscimo da probabilidade depende do expoente considerado.
- \* Este modelo gera redes com distribuição de grau com caudas longas, qualquer que seja a propriedade escolhida e o expoente considerado.

94

94

47

## Redes Aleatórias

- \* **Modelo Ordenação (Rank Model)**
- \* Com escolhas diferentes do expoente obtêm-se distribuições de grau com formas diferentes, o que permite reproduzir distribuições empíricas.
- \* Este modelo permite criar *hubs*, apesar de não incorporar informação detalhada sobre o sistema.

95

95

## Redes Aleatórias

- \* **Modelo Ordenação (Rank Model)**
- \* Um exemplo de aplicação deste modelo é relativo à ligação de novos artigos da *Wikipedia*.
- \* Os autores de artigos procuram ligá-los a artigos relevantes.

96

96

## Redes Aleatórias

- \* **Modelo Ordenação (Rank Model)**
- \* A utilização de motores de busca permite obter uma lista de artigos ordenada por relevância.
- \* Usualmente escolhem-se os artigos da primeira página da lista ordenada.
- \* Esta escolha leva à criação de *hubs*.

97

97

## Redes Aleatórias

- \* **Algumas Aplicações de Redes Aleatórias**
- \* As redes aleatórias podem ser utilizadas para modelar e estudar alguns sistemas complexos.
- \* No caso das redes sociais, alguns estudos permitiram concluir que determinados comportamentos humanos são adoptados mais fácil e rapidamente em redes com *clusters* (ou grupos) do que em redes aleatórias.

98

98

## Redes Aleatórias

- \* **Algumas Aplicações de Redes Aleatórias**

- \* No caso da propagação de doenças, é relevante identificar as subredes em que o contágio ocorrerá mais cedo para desenvolver estratégias de prevenção e tratamento.
- \* A estrutura da rede em estudo poderá ter influência nos resultados, pelo que deve representar bem a população em estudo.

99

99

## Redes Aleatórias

- \* **Algumas Aplicações de Redes Aleatórias**

- \* Outras aplicações consistem no estudo:
  - \* da robustez de redes de abastecimento (eletricidade, gás, ...);
  - \* na propagação de vírus em redes;
  - \* na identificação de pontos sensíveis e fracos numa rede.

100

100

50



## Redes Aleatórias

### \* Algumas Aplicações de Redes Aleatórias

- \* No campo da neurociência, o cérebro pode ser representado por uma rede de neurónios.
- \* Há evidência de que as alterações provocadas pelo Alzheimer condicionam a actividade na rede de neurónios, estando mais próxima da actividade numa rede aleatória do que numa rede representativa de um cérebro saudável.

101

101

## Redes Aleatórias

### \* Algumas Aplicações de Redes Aleatórias

- \* Quais são as vantagens em utilizar redes aleatórias para modelar e estudar sistemas complexos?

102

102

# ANÁLISE DE REDES

## Comunidades

Licenciatura em  
Ciência de Dados

1

1

## Comunidades

- \* Numa rede, os nodos podem estar agrupados em subconjuntos.
- \* Se num subconjunto se observa que os seus elementos têm mais ligações dentro do subconjunto do que ligações para outros nodos, então o subconjunto constitui uma comunidade, cluster ou módulo.


2

2

1

# Comunidades

## \* Exemplo



3

3

# Comunidades

## \* As comunidades estão presentes:

- \* nas redes sociais (as pessoas ou utilizadores apresentam semelhanças);
- \* nas redes biológicas podem representar a interacção das proteínas (grupos de proteínas que interagem e participam na mesma função biológica);

4

4

## Comunidades

- \* As comunidades estão presentes:
  - \* na *Web* (conjuntos de documentos com muitas hiperligações entre si são usualmente sobre temas relacionados).
- \* As comunidades também podem ser identificadas noutras redes.
- \* Um exemplo bastante conhecido é *Zachary's karate club* (no package *igraph* do *R*, `graph("Zachary")`).

5

5

## Comunidades

- \* A estrutura da comunidade permite identificar quais os nodos que têm ligações apenas na comunidade - o *core* da comunidade -, e os nodos que estão na fronteira - os que estão unidos a nodos da comunidade e a outros nodos.
- \* Neste segundo subconjunto estão os elementos cruciais para a transmissão de "informação".

6


6

3

# Comunidades

## \* Exemplo


- \* Considere que os nodos 1, 2, 3, 4, 5 e 6 pertencem à mesma comunidade.



7

# Comunidades

## \* Exemplo



O core da comunidade é constituído pelos nodos 1, 2 e 3.

Na fronteira estão os nodos 4, 5 e 6.

8

8

# Comunidades

- \* A identificação das comunidades é relevante. Em algumas redes este processo é simples e fácil, noutras é mais difícil.
- \* Existem diversas definições de comunidades, umas mais restritivas do que outras.

9

9

# Comunidades

- \* **Conceitos Básicos**
- \* Uma comunidade é uma subrede conexa. Além disso, existem outras condições que terão que ser verificadas.
- \* Seja  $C$  uma comunidade.
  - \* O número de nodos que pertencem a  $C$  é representado por  $N_C$ .
  - \* As ligações internas de  $C$  são as ligações entre os nodos de  $C$ . O número de ligações internas em  $C$  é representado por  $L_C$ .


10

10

5

# Comunidades

## \* Conceitos Básicos



\*  $N_C = 6$ .

\*  $L_C = 10$

\*  $(1,2), (3,6), (2,5)$   
são algumas  
das ligações  
internas.

11

11

# Comunidades

## \* Conceitos Básicos

\* O **grau interno** (*internal degree*) de um nodo  $i$  relativo à comunidade  $C$  -  $k_i^{int}$  - é dado pelo número de ligações entre este nodo e os nodos de  $C$ .

\* O **grau externo** (*external degree*) de um nodo  $i$  relativo à comunidade  $C$  -  $k_i^{ext}$  - é dado pelo número de ligações entre este nodo e os nodos que não pertencem a  $C$ .


\* Naturalmente tem-se  $k_i = k_i^{int} + k_i^{ext}$ .

12

12

# Comunidades

## \* Conceitos Básicos



- \*  $k_1^{int} = 3, k_1^{ext} = 0$ ;
- \*  $k_4^{int} = 3, k_4^{ext} = 1$ ;
- \*  $k_7^{int} = 1, k_7^{ext} = 1$ ;
- \*  $k_8^{int} = 0, k_8^{ext} = 2$ .

13

13

# Comunidades

## \* Conceitos Básicos

- \* Se  $k_i^{ext} = 0$  e  $k_i^{int} > 0$  então o nodo  $i$  é um nodo interno de  $C$ . Este nodo pertence ao *core* da comunidade.
- \* Se  $k_i^{ext} > 0$ ,  $k_i^{int} > 0$  e  $i$  pertence a  $C$  então o nodo  $i$  pertence à fronteira da comunidade (*boundary node*).
- \* Se  $k_i^{int} = 0$  então  $i$  não pertence a  $C$  e não tem ligações à comunidade.


14

14



# Comunidades

## \* Conceitos Básicos



- \* O nó 1 é interno.
- \* O nó 4 está na fronteira.
- \* 7 não pertence à comunidade mas tem ligações a C.
- \* O nó 8 não pertence à comunidade nem tem ligações à comunidade.

15

15

# Comunidades

## \* Conceitos Básicos

- \* A **densidade interna** (*internal link density*) da comunidade C (relativamente às ligações) é dada por

$$d_C^{int} = \frac{L_C}{\binom{N_C}{2}} = \frac{2L_C}{N_C(N_C-1)}.$$

- \* O **grau da comunidade C** (*degree community*) ou **volume** (*volume*) é a soma dos graus dos nós de C,


$$k_C = \sum_{i \in C} k_i.$$

16

16

# Comunidades

## \* Conceitos Básicos



\* A densidade interna de  $C$  é

$$\frac{2 \cdot 10}{6 \cdot 5} = \frac{2}{3}.$$

\* O grau de  $C$  é

$$k_1 + k_2 + k_3 + k_4 + k_5 + k_6 = 23.$$

17

17

# Comunidades

## \* Conceitos Básicos

- \* As definições anteriores aplicam-se a redes não orientadas e sem pesos associados às ligações.
- \* No caso da existência de pesos, os graus são substituídos pelo grau ponderado ou força. Assim, ao grau interno corresponde a **força interna** (*internal strength*) e ao grau externo corresponde a **força externa** (*external strength*).
- \* Para redes orientadas, a aplicação destes conceitos pode carecer de sentido.

18

18

# Comunidades

## \* Definições de Comunidade

- \* Usualmente considera-se que as comunidades são subredes:
  - \* com coesão elevada - têm muitas ligações internas;
  - \* apresentam uma separação elevada - estão ligadas, a outras comunidades ou subredes, por poucas ligações.


19

19

# Comunidades

## \* Definições de Comunidade

### \* Exemplo



- \* As subredes geradas por  $\{1,2,3\}$  e por  $\{4,5,6\}$  são redes completas (apresentam uma coesão muito elevada).
- \* Além disso, estas duas subredes estão unidas apenas por uma ligação, estão bem separadas.

20

20

10

# Comunidades

## \* Definições de Comunidade

- \* As definições de comunidades baseadas apenas na coesão tratam a comunidade como um sistema sem ter em conta o resto da rede.
- \* Quando se define uma comunidade como uma clique, está a considerar-se apenas a coesão.
- \* Contudo, em muitas situações, as comunidades são menos densas e alguns nodos têm associado um papel diferente dos outros membros da comunidade.

21

21

# Comunidades

## \* Definições de Comunidade

- \* Quando se consideram tanto a coesão como a separação espera-se que o número de ligações internas seja superior ao número de ligações externas.
- \* Podem definir-se:
  - \* uma **comunidade forte** (*strong community*) como uma subrede em que cada nodo tem mais adjacentes na subrede que no resto da rede (o grau interno de cada nodo da subrede é superior ao grau externo);

22

22

11

# Comunidades

## \* Definições de Comunidade

### \* Podem definir-se:


- \* uma **comunidade fraca** (*weak community*) como uma subrede em que a soma dos graus internos dos nodos é superior à soma dos graus externos dos nodos.
- \* Uma comunidade forte é também uma comunidade fraca, mas uma comunidade fraca pode não ser uma comunidade forte.

23

23

# Comunidades

## \* Definições de Comunidade



- \* Se a subrede gerada por  $\{1,2,3,4,5,6,9\}$  é uma comunidade.

- \* É uma comunidade fraca porque  $\sum_{i \in C} k_i^{int} > \sum_{i \in C} k_i^{ext}$ .

- \* Não é forte porque  $k_9^{int} < k_9^{ext}$ .

24

24

12

# Comunidades

- \* **Definições de Comunidade**

- \* As definições anteriores centram-se na comunidade e separam-na do resto da rede.
- \* É expectável que o resto da rede seja constituído por outras comunidades.
- \* Esta observação sugere outras definições de comunidades.

25

25

# Comunidades

- \* **Definições de Comunidade**

- \* Naturalmente que se continua a ter em conta a coesão.
- \* Desta forma, se a subrede  $C$  é uma comunidade então espera-se que cada um dos nodos de  $C$  tenha ligações mais fortes com os elementos de  $C$  do que com os elementos dos restantes grupos.

26

26

13

# Comunidades

## \* Definições de Comunidade

- \* Tendo em conta estas observações, propõem-se as novas definições:
  - \* uma comunidade forte (*strong community*) é uma subrede em que cada nodo tem mais adjacentes na subrede do que em cada uma das restantes comunidades;
  - \* uma comunidade fraca (*weak community*) é uma subrede em que a soma dos graus internos dos nodos é superior à soma dos graus externos dos nodos relativos a cada uma das restantes comunidades.

27

27

# Comunidades

## \* Definições de Comunidade


- \* Estas definições são menos restritivas do que as anteriores.
- \* Podem identificar-se subredes que satisfazem as condições das últimas definições, mas não verificam as condições das primeiras definições.

28

28

# Comunidades

## \* Definições de Comunidade



29

# Comunidades

## \* Definições de Comunidade

- \* No exemplo anterior, a subrede gerada por  $\{1,2,3,4\}$  é uma clique.
- \* Esta subrede é uma comunidade forte de acordo com a segunda definição (se se considerar que cada uma das subredes  $\{5,6,7,8\}$  e  $\{9,10,11,12\}$  é uma comunidade).
- \* No entanto, não é uma comunidade forte de acordo com a primeira, porque o nodo 4 tem três nodos adjacentes na subrede e quatro nodos adjacentes que não pertencem à subrede.

30

30

15



## Comunidades

### \* Definições de Comunidade

- \* No exemplo anterior, a subrede gerada por {5,6,7,8} é uma comunidade forte de acordo com as duas definições:

$$k_5^{int} = 2, k_5^{ext} = 1; k_6^{int} = 3, k_6^{ext} = 0;$$

$$k_7^{int} = 3, k_7^{ext} = 1; k_8^{int} = 2, k_8^{ext} = 0.$$

- \* O grau interno de cada nodo é superior ao grau externo, quer se considere o resto da rede ou cada um dos suconjuntos de nodos do resto da rede.

31

31

## Comunidades

### \* Definições de Comunidade

- \* No exemplo anterior, a subrede gerada por {9,10,11,12} é uma comunidade fraca de acordo com as duas definições:

$$k_9^{int} = 3, k_9^{ext} = 1; k_{10}^{int} = 1, k_{10}^{ext} = 1;$$

$$k_{11}^{int} = 2, k_{11}^{ext} = 0; k_{12}^{int} = 2, k_{12}^{ext} = 0.$$

- \* A soma dos graus internos é superior à soma dos graus externos, quer se considere o resto da rede ou um subconjunto dos restantes nodos.
- \* A subrede não pode ser uma comunidade forte porque o grau interno do nodo 10 é igual ao grau externo.

32

32

# Comunidades

## \* Definições de Comunidade

Comunidade Forte	Comparação baseada nos graus de cada nodo	Comparação da comunidade com o resto da rede	Definição mais restritiva
Comunidade Fraca	Comparação baseada na soma dos graus dos nodos	Comparação da comunidade com cada uma das restantes comunidades	Definição menos restritiva

33

33

# Comunidades

## \* Definições de Comunidade

- \* As definições de comunidades já apresentadas baseiam-se no número de ligações e na comparação entre o número de ligações internas e externas de subredes.
- \* Contudo, o número de ligações pode depender da dimensão da subrede, o que pode dificultar ou distorcer a identificação de comunidades.

34

34

# Comunidades

## \* Definições de Comunidade

- \* Em vez de números absolutos, seria útil considerar probabilidades.
- \* Alguns modelos de definição e de detecção de comunidades são baseados em probabilidades.

35

35

# Comunidades

## \* Definições de Comunidade

- \* Por outro lado, a maior parte dos métodos para *clustering* de redes não requer uma definição precisa de comunidade.
- \* No entanto, a definição de critérios para comunidades pode ser útil para verificar a fiabilidade dos resultados obtidos.

36

36

18

# Comunidades

- \* Problemas relacionados com Comunidades
- \* Partição de Redes
- \* Uma partição (*partition*) de uma rede é uma divisão em subredes em que cada nodo pertence a exatamente uma subrede e cada subrede tem pelo menos um nodo. Além disso, o conjunto de ligações não sofre alterações.

37

37

# Comunidades

- \* Problemas relacionados com Comunidades
- \* Partição de Redes
- \* O número de possíveis partições é designado por número de Bell (*Bell number*).
- \* Este número cresce exponencialmente com o número de elementos da rede.
- \* Para uma rede com 10 nodos existem mais de 20 000 partições.

38

38

# Comunidades

- \* **Problemas relacionados com Comunidades**
- \* **Partição de Redes**
- \* Assim, torna-se impossível obter todas as partições e escolher a melhor.
- \* Por este motivo, os algoritmos de *clustering* consideram apenas uma pequena fracção das partições possíveis.

39

39

# Comunidades

- \* **Problemas relacionados com Comunidades**
- \* **Partição de Redes**
- \* A identificação de comunidades não sobrepostas (comunidades disjuntas) corresponde à determinação de partições com algumas propriedades.
- \* No caso de comunidades com possíveis sobreposições (um ou mais nodos podem pertencer a mais do que uma comunidade), a divisão da rede é designada por cobertura (*cover*).
- \* O número de coberturas é ainda superior ao número de partições.

40

40

20

# Comunidades

- \* **Problemas relacionados com Comunidades**
- \* **Partição de Redes**
  - \* As partições podem ser hierárquicas. Estas partições surgem quando a rede possui diversos níveis de organização em diferentes escalas.
  - \* Neste caso, os grupos ou *clusters* apresentam uma estrutura em que cada comunidade pode subdividir-se noutras mais pequenas.

41

41

# Comunidades

- \* **Problemas relacionados com Comunidades**
- \* **Partição de Redes**
  - \* Um centro hospitalar pode ser composto por diversos hospitais. Em cada um dos hospitais há diversos grupos, comunidades profissionais ou serviços.
  - \* Existem também ligações entre os diferentes hospitais, mas em número inferior ao de ligações em cada hospital.

42

42

21

# Comunidades

- \* **Problemas relacionados com Comunidades**

- \* **Partição de Redes**

- \* As partições de redes reais são frequentemente heterógeneas, no sentido em que apresentam propriedades que variam muito de um grupo para outro.
- \* Por exemplo, muitas vezes existe uma grande diferença entre a dimensão de cada comunidade da mesma rede.

43

43

# Comunidades

- \* **Problemas relacionados com Comunidades**

- \* **Partição de Redes**

- \* Na Web há grupos ou *clusters* (que resultam do tema abordado) com milhões de páginas e outros com milhares.
- \* A coesão também pode ser muito diversa, alguns grupos apresentam uma densidade interna bastante superior à de outros.

44

44

22

# Comunidades

- \* **Problemas relacionados com Comunidades**

- \* **Partição de Redes**

- \* Usualmente as comunidades estão bem separadas de outras comunidades.
- \* A identificação de subredes bem separadas é o objectivo da partição de uma rede.
- \* A ênfase está na separação e não na coesão.

45

45

# Comunidades

- \* **Problemas relacionados com Comunidades**

- \* **Partição de Redes**

- \* Por este motivo, os métodos de partição não são adequados para a detecção de comunidades.
- \* No entanto, algumas técnicas de partição são utilizadas, em conjunto com outros procedimentos, na detecção de comunidades.

46

46



# Comunidades

- \* **Problemas relacionados com Comunidades**

- \* **Partição de Redes**

- \* O problema de partição consiste em dividir uma rede em subredes de determinada dimensão de forma a minimizar o número de ligações entre as subredes.
- \* Este conjunto de ligações é designado por corte (cut), porque a remoção destas ligações deixa a rede desconexa.

47

47

# Comunidades

- \* **Problemas relacionados com Comunidades**

- \* **Partição de Redes**

- \* O número de elementos do corte é designado dimensão do corte (cut size).
- \* O problema de partição de uma rede também é conhecido como o problema de minimização do corte.

48

48

# Comunidades

- \* **Problemas relacionados com Comunidades**
- \* **Partição de Redes**
- \* A resolução deste problema requer a indicação do número de subconjuntos e a dimensão aproximada de cada subconjunto (para evitar obter soluções triviais como um só subconjunto constituído por toda a rede ou dois subconjuntos tendo um deles apenas um dos nodos da rede).

49

49

# Comunidades

- \* **Problemas relacionados com Comunidades**
- \* **Partição de Redes**
- \* Um dos algoritmos mais antigos e mais conhecidos para a bissecção de uma rede (partição em dois subconjuntos) é o algoritmo de Kernighan-Lin.
- \* Considera-se uma bissecção inicial da rede. O número de elementos em cada subconjunto é igual ou difere apenas numa unidade.

50

50

25

# Comunidades

- \* **Problemas relacionados com Comunidades**
- \* **Partição de Redes**
- \* O algoritmo consiste na troca de pares de nodos.
- \* Em cada troca, consideram-se dois nodos pertencentes a subconjuntos diferentes e transfere-se cada um dos nodos para o outro subconjunto. Assim, a dimensão de cada subconjunto não se altera.
- \* O par de nodos é escolhido de forma a reduzir o número de ligações entre os dois subconjuntos.

51

51

# Comunidades

- \* **Problemas relacionados com Comunidades**
- \* **Partição de Redes**
- \* **Algoritmo de Kernighan-Lin**
- \* Começa-se com uma partição arbitrária  $P$  da rede em dois subconjuntos  $A$  e  $B$ . Por exemplo, escolhem-se aleatoriamente metade dos nodos e atribuem-se a um dos subconjuntos. Os restantes nodos são incluídos no outro subconjunto.

52

52

# Comunidades

- \* Problemas relacionados com Comunidades
- \* Partição de Redes
- \* Algoritmo de Kernighan-Lin
- \* Cada iteração é constituída pelos seguintes passos:
  - \* 1 - Para cada par  $(i, j)$ ,  $i \in A$  e  $j \in B$ , calcula-se o impacto na dimensão do corte resultante de mudar  $i$  para  $B$  e  $j$  para  $A$ ;
  - \* 2 - O par  $(i^*, j^*)$  com a maior redução associada é escolhido e trocam-se os nodos. O par de nodos escolhido é bloqueado e os nodos não voltarão a ser escolhidos nesta iteração;

53

53

# Comunidades

- \* Problemas relacionados com Comunidades
- \* Partição de Redes
- \* Algoritmo de Kernighan-Lin
- \* 3 - Repetem-se os passos 1 e 2 até não se conseguir reduzir a dimensão do corte, através da troca de pares de nodos não bloqueados.
- \* O algoritmo termina quando não se consegue reduzir a dimensão do corte.

54

54

# Comunidades

- \* Problemas relacionados com Comunidades
- \* Partição de Redes
- \* Algoritmo de Kernighan-Lin
- \* Pode adaptar-se este algoritmo de forma a considerar mais do que dois subconjuntos.
- \* As soluções determinadas por este algoritmo dependem da partição inicial.

55

55

# Comunidades

- \* Problemas relacionados com Comunidades
- \* Partição de Redes
- \* Algoritmo de Kernighan-Lin
- \* Além disso, trata-se de uma heurística *greedy*, porque se escolhe a troca mais conveniente para cada uma das iterações, sem a possibilidade de alterar posteriormente as escolhas anteriores.
- \* Este método pode ser utilizado para melhorar soluções geradas por outros métodos.

56

56

28

# Comunidades

- \* **Problemas relacionados com Comunidades**
- \* **Partição de Redes**
- \* A partição das redes tem a desvantagem de ter apenas como objectivo a separação, ignorando a coesão.
- \* Por outro lado, é necessário especificar o número de subconjuntos pretendidos em vez de escolher este número com base nos dados.

57

57

# Comunidades

- \* **Problemas relacionados com Comunidades**
- \* **Partição de Redes**
- \* Contudo, a partição de redes pode ser aplicada a diversos problemas: processamento de imagem, dinâmica de fluidos, controlo de tráfego aéreo, computação em paralelo,...

58

58

# Comunidades

- \* **Problemas relacionados com Comunidades**
- \* ***Data Clustering***
- \* As comunidades procuram agrupar nodos com características comuns.
- \* Pode concluir-se que o problema de detecção de comunidades é um caso especial de um problema bastante mais geral - *data clustering* -, que procura agrupar dados com base em alguma noção de similaridade.

59

59

# Comunidades

- \* **Problemas relacionados com Comunidades**
- \* ***Data Clustering***
- \* Alguns conceitos e ferramentas relativos ao *data clustering* podem ser utilizados em redes.
- \* Os modelos hierárquicos de *data clustering* geram um conjunto de partições, enquanto que os modelos de partição fornecem apenas uma partição.

60

60

30

# Comunidades

- \* **Problemas relacionados com Comunidades**
- \* ***Data Clustering***
- \* Frequentemente a escolha para adaptar modelos de *data clustering* para *clustering* em redes recai sobre os modelos hierárquicos.

61

61

# Comunidades

- \* **Problemas relacionados com Comunidades**
- \* ***Data Clustering***
- \* É necessária uma medida de similaridade para efectuar o agrupamento.
- \* Se for possível representar os nodos num plano geométrico, pode considerar-se a distância entre os nodos. Quanto mais próximos, mais similares serão os nodos.

62

62



# Comunidades

- \* **Problemas relacionados com Comunidades**

- \* **Data Clustering**

- \* Outra alternativa consiste em recorrer à estrutura da rede. A equivalência estrutural (*strutural equivalence*) baseia-se na similaridade entre os nodos adjacentes. Pode definir-se:

$$S_{ij}^{SE} = \frac{\text{número de nodos adjacentes comuns de } i \text{ e } j}{\text{número de nodos adjacentes de } i, \text{ ou de } j \text{ ou de ambos}}$$

63

63

# Comunidades

- \* **Problemas relacionados com Comunidades**

- \* **Data Clustering**

- \* Quanto à similaridade entre dois conjuntos de nodos, pode ser medida através das ligações entre os dois conjuntos.
- \* Para tal, será necessário determinar os *scores* dos pares de nodos que pertencem a conjuntos diferentes.

64

64

# Comunidades

## \* Problemas relacionados com Comunidades

### \* Data Clustering

- \* Dada uma medida de similaridade  $S$  e dois conjuntos de nodos  $G_1$  e  $G_2$ , a similaridade entre  $G_1$  e  $G_2$  será feita com base nos *scores* dos pares de nodos. Podem considerar-se:

- \*  $S_{G_1G_2} = \max_{i,j} S_{ij}$  (*simple linkage*);
- \*  $S_{G_1G_2} = \min_{i,j} S_{ij}$  (*complete linkage*);
- \*  $S_{G_1G_2} = \langle S_{ij} \rangle_{i,j}$  (*average linkage*).

65

65

# Comunidades

## \* Problemas relacionados com Comunidades

### \* Data Clustering

- \* Os métodos hierárquicos de *clustering* podem ser aglomerativos (juntam grupos de nodos) ou podem consistir na divisão de grupos.
- \* Os métodos hierárquicos de *clustering* aglomerativos começam com uma partição com  $N$  grupos.
- \* Em cada grupo há apenas um nodo. Em cada passo, cada par de grupos com maior similaridade é fundido e o número de grupos diminui em uma unidade.

66

66

## Comunidades

- \* **Problemas relacionados com Comunidades**
- \* *Data Clustering*
- \* Este passo é repetido até todos os nodos estarem no mesmo grupo.
- \* Estes métodos geram  $N$  partições que podem ser representadas num dendrograma.

67

67

## Comunidades

- \* **Problemas relacionados com Comunidades**
- \* *Data Clustering*
- \* O *clustering* hierárquico apresenta diversas limitações.
- \* Gera um número de partições igual ao número de nodos sem indicação de um critério para escolher a partição mais indicada.

68

68

# Comunidades

- \* **Problemas relacionados com Comunidades**
- \* **Data Clustering**
- \* Os resultados destes métodos dependem da medida de similaridade adoptada.
- \* Estes algoritmos são muito lentos não sendo aplicáveis para redes com uma dimensão muito elevada.

69

69

# Comunidades

- \* **Problemas relacionados com Comunidades**
- \* **Determinação de cliques**
- \* Uma clique é uma subrede completa.
- \* A definição de comunidade como uma clique é muito restritiva e está baseada apenas na coesão e não na separação.
- \* Além disso, esta definição pode gerar uma partição da rede com um número excessivo de comunidades.

70

70

# Comunidades

- \* **Problemas relacionados com Comunidades**
- \* **Determinação de cliques**
- \* A identificação da clique com o número máximo de nodos (*maximal clique*) é um problema com aplicações em redes sociais, bioinformática, química computacional,...
- \* Este problema pode ser resolvido com recurso a heurísticas ou a Programação Linear Inteira.

71

71

# Comunidades

- \* **Detecção de Comunidades**
- \* Existem muitos métodos de detecção de comunidades. Vamos estudar apenas alguns.
- \* Estudaremos também um método de avaliação.

72

72

## Comunidades

- \* **Detecção de Comunidades**
- \* **Remoção de Pontes**
- \* Uma ponte (*bridge*) é uma ligação cuja remoção divide uma rede conexa em duas subredes.
- \* No caso de ser possível identificar todas as pontes de uma rede, a remoção destas pontes iria dividir a rede em subredes e a identificação de comunidades seria imediata.

73

73

## Comunidades

- \* **Detecção de Comunidades**
- \* **Remoção de Pontes**
- \* Nos métodos de remoção de pontes é necessária uma medida que permita a identificação de pontes.
- \* No algoritmo de Girvan e Newmann, esta medida é a intermediação de ligações (baseada no número de caminhos mais curtos que passam por uma ligação).

74

74

# Comunidades

- \* **Detecção de Comunidades**
- \* **Remoção de Pontes**
- \* É expectável que as ligações com maior intermediação sejam as que unem comunidades, em vez das ligações internas às comunidades.

75

75

# Comunidades

- \* **Detecção de Comunidades**
- \* **Remoção de Pontes**
- \* Em cada iteração deste algoritmo, identifica-se a ligação com maior intermediação e remove-se esta ligação.
- \* Recalcula-se depois a intermediação das ligações, com vista a escolher a próxima ligação a ser retirada.

76

76

# Comunidades

- \* **Detecção de Comunidades**
- \* **Remoção de Pontes**
- \* Durante a aplicação do algoritmo o número de componentes conexas vai aumentando.
- \* O algoritmo termina após a remoção de todas as ligações.

77

77

# Comunidades

- \* **Detecção de Comunidades**
- \* **Remoção de Pontes**
- \* **Algoritmo de Girvan e Newmann**
- \* Começa-se por determinar a intermediação de cada ligação. Cada iteração consiste nos passos:
  - \* 1 - Remove-se a ligação com maior intermediação. No caso de empate, escolhe-se uma das ligações com intermediação mais elevada;

78

78



# Comunidades

- \* **Detecção de Comunidades**
- \* **Remoção de Pontes**
- \* **Algoritmo de Girvan e Newmann**
  - \* 2 - Recalcula-se a intermediação para cada uma das restantes ligações.
- \* O algoritmo termina quando todas as ligações tiverem sido removidas.

79

79

# Comunidades

- \* **Detecção de Comunidades**
- \* **Remoção de Pontes**
- \* Em cada iteração é necessário recalcular as medidas de intermediação, o que pode tornar o algoritmo muito lento.
- \* Se a rede tiver uma estrutura de comunidades fortes, rapidamente a rede fica dividida em componentes conexas.

80

80

# Comunidades

- \* **Detecção de Comunidades**
- \* **Remoção de Pontes**
- \* Este algoritmo gera  $N$  partições.
- \* A primeira inclui todos os elementos da rede e em cada iteração cada *cluster* é dividido em dois.
- \* Trata-se, por isso, de um método hierárquico de *clustering* de divisão.

81

81

# Comunidades

- \* **Detecção de Comunidades**
- \* **Remoção de Pontes**
- \* Por se tratar de um método lento, torna-se impraticável a sua aplicação para redes de dimensão elevada.
- \* Para tornar o método mais rápido, o cálculo da intermediação pode ser substituído por valores baseados numa amostra de ligações.

82

82

41

## Comunidades

- \* **Detecção de Comunidades**
- \* **Remoção de Pontes**
- \* Outra desvantagem do método é a obtenção muitas partições sem indicação sobre a sua qualidade.
- \* Torna-se necessário considerar uma medida para avaliar a qualidade das partições.

83

83

## Comunidades

- \* **Detecção de Comunidades**
- \* **Optimização da Modularidade**
- \* Quando se pretende identificar as comunidades numa rede ou obter uma ou mais partições de uma rede, há interesse em avaliar as soluções obtidas.

84

84

# Comunidades


- \* **Detecção de Comunidades**
- \* **Optimização da Modularidade**
- \* As subredes da partição devem assemelhar-se a comunidades.
- \* Com vista a obter subredes coesas, pode determinar-se a densidade interna e verificar se toma valores elevados.
- \* No entanto, a escolha com base na densidade pode não produzir bons resultados.

85

85

# Comunidades

- \* **Detecção de Comunidades**
- \* **Optimização da Modularidade**
- \* **Exemplo**



86

86

## Comunidades

- \* **Detecção de Comunidades**
- \* **Optimização da Modularidade**
- \* **Exemplo**
- \* Se se considerarem duas comunidades, uma gerada por  $\{1,2,3,4\}$  e outra por  $\{5,6,7,8\}$  então a densidade interna de cada comunidade é igual a um (que é o valor máximo para a densidade).

87

87

## Comunidades

- \* **Detecção de Comunidades**
- \* **Optimização da Modularidade**
- \* **Exemplo**
- \* Contudo, estas duas comunidades estariam separadas por quatro ligações e cada uma teria seis ligações internas. Estariam separadas por um número excessivo de ligações.
- \* Considerando apenas uma comunidade, a densidade será igual a 0,57.

88

88

# Comunidades

- \* **Detecção de Comunidades**
- \* **Optimização da Modularidade**
- \* Outra ideia para avaliar as partições consiste em comparar com redes em que não existem comunidades.
- \* Nas redes aleatórias, redes em que as ligações são escolhidas aleatoriamente, não é expectável encontrar comunidades.
- \* Assim, pode comparar-se o número de ligações internas de cada subrede da partição com o número esperado de ligações existentes numa rede aleatória.

89

89

# Comunidades

- \* **Detecção de Comunidades**
- \* **Optimização da Modularidade**
- \* A modularidade é uma medida baseada nesta ideia.
- \* Contudo, não se trata de uma medida que produz valores absolutos.
- \* Esta medida calcula um valor que pretende medir as diferenças entre a rede em estudo e a estrutura de uma rede aleatória.

90

90

# Comunidades

- \* **Detecção de Comunidades**
- \* **Optimização da Modularidade**
- \* Se o número de ligações internas de cada subrede for bastante superior ao número esperado numa rede aleatória então é pouco provável que a concentração elevada de ligações resulte de um processo aleatório.

91

91

# Comunidades

- \* **Detecção de Comunidades**
- \* **Optimização da Modularidade**
- \* No caso de o número de ligações internas de cada subrede ser bastante superior ao número esperado numa rede aleatória, o valor da modularidade será mais elevado.
- \* Caso contrário, o número de ligações internas de cada subrede for aproximado do número esperado numa rede aleatória então a modularidade tomará um valor mais baixo.

92

92

# Comunidades

- \* **Detecção de Comunidades**
- \* **Optimização da Modularidade**
- \* No cálculo da modularidade de uma partição, considera-se que  $C$  representa um elemento da partição (um subconjunto) e utiliza-se uma aproximação da probabilidade de escolher ao acaso uma ligação de uma rede aleatória que una dois elementos de  $C$ .
- \* Se a rede for não orientada e sem pesos associados às ligações, a probabilidade aproximada de escolher aleatoriamente um dos nodos de  $C$  unidos pela ligação é dada por  $\frac{k_C}{2L}$ .

93

93

# Comunidades

- \* **Detecção de Comunidades**
- \* **Optimização da Modularidade**
- \* Então a probabilidade de escolher ao acaso uma ligação de uma rede aleatória que una dois elementos de  $C$  será aproximada por  $\frac{k_C}{2L} \cdot \frac{k_C}{2L}$ . O valor esperado de ligações internas em  $C$  será

$$L \cdot \frac{k_C}{2L} \cdot \frac{k_C}{2L} = \frac{k_C^2}{4L}$$

94

94

47



# Comunidades

- \* **Detecção de Comunidades**
- \* **Optimização da Modularidade**
- \* Obtém-se então

$$Q = \frac{1}{L} \sum_c \left( L_c - \frac{k_c^2}{4L} \right)$$

- \* O valor de  $Q$  será sempre inferior a 1.
- \* Se existir apenas um *cluster* então  $Q = 0$ .
- \* O valor de  $Q$  pode ser negativo. Se existirem  $N$  clusters então o valor de  $Q$  será negativo.

95

95

# Comunidades

- \* **Detecção de Comunidades**
- \* **Optimização da Modularidade**
- \* A modularidade também pode ser definida para redes orientadas. Basta substituir o grau pelo grau incidente e grau divergente obtendo-se

$$Q_d = \frac{1}{L} \sum_c \left( L_c - \frac{k_c^{in} k_c^{out}}{L} \right)$$

96

96

# Comunidades

- \* **Detecção de Comunidades**
- \* **Optimização da Modularidade**
- \* Para redes com pesos associados às ligações tem-se

$$* Q_w = \frac{1}{W} \sum_C \left( W_C - \frac{s_C^2}{4W} \right)$$

em que  $W$ ,  $W_C$  e  $s_C$  representam, respectivamente, a soma dos pesos das ligações da rede, a soma dos pesos das ligações internas de  $C$  e a força dos nodos em  $C$ .

97

97

# Comunidades

- \* **Detecção de Comunidades**
- \* **Optimização da Modularidade**
- \* Para redes orientadas e com pesos associados às ligações tem-se

$$Q_{dw} = \frac{1}{W} \sum_C \left( W_C - \frac{s_C^{in} s_C^{out}}{W} \right)$$

98

98

# Comunidades

- \* **Detecção de Comunidades**
- \* **Optimização da Modularidade**
- \* A modularidade foi inicialmente introduzida para avaliar as soluções obtidas pelo algoritmo de Girvan-Newmann e escolher a melhor solução.
- \* No entanto, a modularidade pode ser utilizada para avaliar qualquer partição. Assim, também podem considerar-se métodos de optimização de modularidade.

99

99

# Comunidades

- \* **Detecção de Comunidades**
- \* **Optimização da Modularidade**
- \* Como o número de partições de uma rede é bastante elevado, torna-se impossível obter e avaliar todas as partições.
- \* Os métodos de optimização de modularidade, consideram apenas um pequeno subconjunto de partições.

100

100

50

# Comunidades

- \* **Detecção de Comunidades**
- \* **Optimização da Modularidade**
  - \* Um método simples, e aglomerativo, de optimização de modularidade consiste em começar com conjuntos singulares e em cada iteração fundir dois grupos.
  - \* A partição inicial tem um valor negativo de modularidade.

101

101

# Comunidades

- \* **Detecção de Comunidades**
- \* **Optimização da Modularidade**
  - \* Em cada iteração, a fusão escolhida é a que gera um maior aumento da modularidade.
  - \* O método termina com apenas um grupo (com todos os nodos da rede).
  - \* O método explora uma hierarquia de partições que pode ser representada por um dendrograma.

102

102

# Comunidades

- \* **Detecção de Comunidades**
- \* **Optimização da Modularidade**
  - \* Durante a execução do método, o valor da modularidade começa por crescer até atingir o valor mais elevado.
  - \* Depois decresce até tomar o valor nulo (quando se obtém apenas um grupo).
  - \* A partição escolhida será a que tem o valor mais elevado de modularidade. Este método é uma heurística *greedy*.

103

103

# Comunidades

- \* **Detecção de Comunidades**
- \* **Optimização da Modularidade**
  - \* Por se tratar de uma heurística *greedy*, o método tende a obter soluções que não atingem o valor máximo da modularidade.
  - \* Além disso, o método pode obter soluções em que a dimensão dos grupos varia muito.
  - \* Estas soluções podem não ser adequadas. A fusão de grupos pode mitigar esta desvantagem.

104

104

# Comunidades

- \* **Detecção de Comunidades**
- \* **Optimização da Modularidade**
- \* Existem diversos métodos de optimização de modularidade.
- \* Um dos mais utilizados é o algoritmo de Louvain, que é aglomerativo e que agrupa as comunidades em supernodos.

105

105

# Comunidades

- \* **Detecção de Comunidades**
- \* **Optimização da Modularidade**
- \* **Algoritmo de Louvain**
- \* A solução inicial é composta por conjuntos singulares.
- \* Cada iteração do algoritmo consiste em dois passos:

106

106

# Comunidades

- \* **Detecção de Comunidades**
- \* **Optimização da Modularidade**
- \* **Algoritmo de Louvain**
  - \* 1 - Cada nodo é atribuído à comunidade de um dos nodos adjacentes. O nodo adjacente é escolhido de forma a obter o maior aumento da modularidade face à solução actual. Os nodos são inspeccionados diversas vezes até não ser possível incrementar o valor da modularidade;

107

107

# Comunidades

- \* **Detecção de Comunidades**
- \* **Optimização da Modularidade**
- \* **Algoritmo de Louvain**
  - \* 2 - Transforma-se a rede numa rede com supernodos e com pesos associados às ligações. Cada comunidade determinada no passo anterior é substituída por um supernodo. As ligações terão peso igual à soma dos pesos das ligações entre as comunidades representadas nos supernodos. Criam-se lacetes com peso igual à soma dos graus internos.

108

108

# Comunidades

- \* **Detecção de Comunidades**
- \* **Optimização da Modularidade**
- \* **Algoritmo de Louvain**
- \* No passo 1, a modularidade é calculada com base na rede original.
- \* O algoritmo termina quando não se consegue aumentar a modularidade.
- \* Ver exemplo de DOI: [10.1088/1742-5468/2008/10/P10008](https://doi.org/10.1088/1742-5468/2008/10/P10008)

109

109

# Comunidades

- \* **Detecção de Comunidades**
- \* **Optimização da Modularidade**
- \* **Algoritmo de Louvain**
- \* Trata-se de um algoritmo *greedy*, que produz soluções que usualmente não estão próximas da óptima.
- \* A solução gerada pelo método depende da ordem pela qual os nodos são visitados.
- \* O método reduz a dimensão da rede muito rapidamente, sendo, por isso, bastante utilizado.

110

110



# Comunidades

- \* **Detecção de Comunidades**
- \* **Optimização da Modularidade**
- \* A modularidade apresenta algumas limitações.
- \* O valor máximo tende a ser mais elevado em redes de maior dimensão, o que não permite a comparação entre redes de dimensões diferentes.
- \* Apesar de a modularidade ser uma medida que procura medir as diferenças entre a rede em estudo e a estrutura de uma rede aleatória, pode assumir valores elevados para algumas redes aleatórias.

111

111

# Comunidades

- \* **Detecção de Comunidades**
- \* **Optimização da Modularidade**
- \* A medida é baseada no valor esperado de ligações em cada comunidade, mas não tem em conta flutuações aleatórias em torno do valor esperado.

112

112

# Comunidades

- \* **Detecção de Comunidades**
- \* **Optimização da Modularidade**
  - \* Além disso, o valor máximo da modularidade pode não estar associado à melhor partição.
  - \* Isto acontece porque a modularidade pode não determinar comunidades de pequena dimensão.
  - \* As comunidades com grau inferior a  $\sqrt{2L}$  podem não ser identificadas.

113

113

# Comunidades

- \* **Detecção de Comunidades**
- \* **Optimização da Modularidade**
- \* **Exemplo**
  - \* Considere-se uma rede constituída por 16 cliques, cada uma com 4 nodos, e com uma ligação entre cada clique.
  - \* A partição em que cada clique corresponde a uma comunidade tem um valor de modularidade ( $\approx 0,795$ ) inferior à partição em que cada subconjunto abrange duas cliques ( $\approx 0,804$ ).

114

114

# Comunidades

- \* **Detecção de Comunidades**
- \* **Optimização da Modularidade**
- \* Para contornar esta desvantagem, pode introduzir-se, na definição de modularidade, um parâmetro que tenha em conta a dimensão da comunidade.
- \* Esta introdução requer a escolha de um valor para este parâmetro (que deve ser adequado para a rede).

115

115

# Comunidades

- \* **Detecção de Comunidades**
- \* **Optimização da Modularidade**
- \* Por outro lado, a modularidade deve ser otimizada para diversas escolhas do parâmetro.
- \* Esta modificação requer algum esforço computacional. Apesar disso, esta técnica é muito utilizada.

116

116

# Comunidades

- \* **Detecção de Comunidades**
- \* **Propagação de Etiquetas**
- \* Trata-se de um método simples e rápido de detecção de comunidades, baseado na ideia de que nodos adjacentes pertencem à mesma comunidade.

117

117

# Comunidades

- \* **Detecção de Comunidades**
- \* **Propagação de Etiquetas**
- \* Desta forma, espera-se que a maioria das ligações seja interna e que as comunidades sejam coesas e bem separadas.

118

118

# Comunidades

- \* **Detecção de Comunidades**
- \* **Propagação de Etiquetas**
- \* Em cada passo, o algoritmo inspecciona cada nodo e afeta-o à comunidade da maioria dos adjacentes.
- \* Começa-se por atribuir uma etiqueta distinta a cada nodo.

119

119

# Comunidades

- \* **Detecção de Comunidades**
- \* **Propagação de Etiquetas**
- \* O método consiste na repetição dos seguintes passos:
  - \* 1 - Inspeccionam-se todos os nodos, a ordem é aleatória. Cada nodo recebe a etiqueta da maioria dos seus adjacentes. Em caso de empate, escolhe-se aleatoriamente uma das etiquetas mais frequentes.

120

120

# Comunidades

- \* **Detecção de Comunidades**
- \* **Propagação de Etiquetas**
  - \* 2 - Se todos os nodos têm a etiqueta da maioria dos seus adjacentes (estado de estacionaridade), o algoritmo termina. Caso contrário, volta-se ao passo 1.
- \* As comunidades são os grupos com etiquetas iguais, no estado estacionário.

121

121

# Comunidades

- \* **Detecção de Comunidades**
- \* **Propagação de Etiquetas**
  - \* As etiquetas propagam-se durante a execução do algoritmo. Algumas desaparecem, enquanto que outras se tornam mais frequentes.

122

122

# Comunidades

- \* **Detecção de Comunidades**
- \* **Propagação de Etiquetas**
- \* Durante a execução do algoritmo ocorrem diversas mudanças, no entanto, o algoritmo converge usualmente após um número pequeno de iterações, independentemente da dimensão da rede.

123

123

# Comunidades

- \* **Detecção de Comunidades**
- \* **Propagação de Etiquetas**
- \* Na solução gerada, cada nodo tem mais adjacentes na sua comunidade do que em qualquer uma das outras comunidades.
- \* Por isso, este algoritmo gera comunidades fortes no sentido da definição menos restritiva.

124

124

# Comunidades

- \* **Detecção de Comunidades**
- \* **Propagação de Etiquetas**
- \* A solução gerada pelo algoritmo pode depender da ordem de inspecção dos nodos e dos empates, o que poderá ser considerado uma desvantagem.

125

125

# Comunidades

- \* **Detecção de Comunidades**
- \* **Propagação de Etiquetas**
- \* Para aplicar este algoritmo não é necessária informação sobre o número nem a dimensão das comunidades.
- \* O método não tem parâmetros.
- \* Trata-se, por isso, de um método simples, rápido e que pode ser aplicado a redes com dimensão elevada.

126

126



# Comunidades

- \* **Detecção de Comunidades**
- \* **Propagação de Etiquetas**
- \* Se se conhecer uma estrutura de comunidades para alguns dos nodos, esta informação pode ser utilizada para definir as etiquetas iniciais.

127

127

# Comunidades

- \* **Detecção de Comunidades**
- \* **Comunidades Sobrepostas**
- \* Em algumas situações, alguns nodos podem pertencer a mais do que uma comunidade. Estas comunidades são usualmente designadas por comunidades sobrepostas (*overlapping communities*).
- \* Existem métodos para detectar comunidades sobrepostas (Algoritmo CFinder,...). Estes métodos não pertencem aos conteúdos desta Unidade Curricular.

128

128

# Comunidades

- \* **Avaliação dos Métodos de Detecção de Comunidades**
- \* Como se pode aferir a qualidade de um método de detecção de comunidades?
- \* Dados dois métodos, qual é o melhor?
- \* Estas perguntas não têm uma resposta fácil.

129

129

# Comunidades

- \* **Avaliação dos Métodos de Detecção de Comunidades**
- \* Uma forma de avaliar os métodos consiste em aplicá-los a um conjunto de instâncias (*benchmark*) de redes com estruturas de comunidades naturais e analisar os resultados obtidos.
- \* Existem instâncias artificiais criadas para testar métodos e instâncias reais com estruturas de comunidades.

130

130

# Comunidades

## \* Avaliação dos Métodos de Detecção de Comunidades

- \* Uma das instâncias reais mais conhecidas é a do clube de Karatê de Zachary. Um bom método deve identificar duas comunidades nesta rede.
- \* Além dos testes em instâncias com comunidades, podem também ser consideradas instâncias sem comunidades para avaliar o comportamento dos métodos. Caso identifiquem comunidades, os métodos não serão fiáveis.

131